

智慧医疗 共创健康

基于图神经网络的药物重定位

DRUG REPURPOSING BASED ON GNN

MEDICAL HEALTH

网络技术挑战赛A赛项

团队名称：东东队

目 录

一、目标问题与意义价值	4
1.1 产业背景	4
1.1.1 生物医药时代背景	4
1.1.2 生物医药研发现状	4
1.2 市场分析	6
1.2.1 宏观分析	6
1.2.2 微观分析	8
1.3 需解决的问题	9
1.4 研究目标	9
1.5 应用价值	9
1.5.1 学科交叉应用实现医药产业升级	9
1.5.2 助力国家科技创新	10
1.5.3 打破专业壁垒，增加就业机会	10
二、设计思路与方案	11
2.1 药物重定位研究现状	11
2.1.1 药物-靶点相互作用预测研究现状	11
2.1.2 药物-疾病相互作用预测研究现状	12
2.2 设计思路	14
2.3 技术路线	15
2.3.1 基于图信息融合的 Transformer 用于药物-靶点相互作用预测	15
2.3.2 基于邻域对比学习异构图神经网络药物重定位模型	15
2.4 设计方案	15
2.4.1 基于图信息融合的 Transformer 网络的设计方案	15
2.4.1.1 算法概述	15
2.4.1.2 药物嵌入表示	17
2.4.1.3 靶点嵌入表示	19
2.4.1.4 关系预测及优化	21
2.4.2 基于邻域对比学习异构图神经网络的设计方案	21
2.4.2.1 数据及异构网络构建	21
2.4.2.2 HNNCL 模型结构	22
三、方案实现	27
3.1 基于图信息融合的 Transformer 用于药物-靶点相互作用预测	27
3.1.1 实验数据	27
3.1.2 实验设置	27
3.1.3 评价指标	27
3.1.4 Deep MGT 在对比试验中的性能	28
3.1.5 消融实验	29
3.1.6 Deep MGT 在不平衡数据中的性能	30
3.1.7 案例探究：Deep MGT 用于 COVID-19 的药物重定位研究	30
3.2 基于邻域对比学习异构图神经网络药物重定位模型	32
3.2.1 实验设置	32
3.2.2 HNNCL 在交叉验证中的性能	32

3.2.3 消融实验	33
3.2.4 多邻域聚合节点数量对 HNNCL 性能的影响	35
3.2.5 案例探究：HNNCL 用于阿尔茨海默症的药物重定位研究	35
四、运行结果/应用效果	37
4.1 项目依赖环境	37
4.1.1 DeepMGT-DTI	37
4.1.2 HNNCL	37
4.2 应用结果	38
五、创新与特色	40
5.1 项目创新	40
5.2 项目特色	40
六、总结	41
七、参考文献	42

一、目标问题与意义价值

1.1 产业背景

1.1.1 生物医药时代背景

生物医药产业对国民经济和人类社会意义重大，除了保障人民健康外，也是科技和人才的象征，已经逐渐成为大国竞争的重要领域。从国际生物技术、生物经济竞争的趋势看，美国、欧洲等许多国家政府都高度重视发展医药生物技术，全世界有 14 个国家的领导人亲自兼任有关生物技术机构的负责人。推动生物医药经济的发展，生物医药经济已经成为决战未来的分水岭。从世界科技和经济发展规律来看，谁占据了科技中心的位置，谁就逐渐拥有经济实力、军事实力、政治影响力、文化影响力，医药生物科技也将是核心科技之一。

从国内政策环境来看，“十三五”时期，我国生物医药产业在疫苗、抗体和蛋白质药物产业化、重大疾病诊断和检测技术的研发、基因治疗、细胞治疗以及再生医学技术的研究与应用等方面皆取得了重大成就，这也使生物医药产业逐步成为国家支柱产业。据统计，截至“十三五”收官之年，我国生物医药行业的市场规模已达到了 35700 亿元，其彰显出的发展潜力不容小觑。

虽然近些年我国对于生物医药产业的研发投入逐年增长，但由于起步时间较晚且投入有限，我国在研发方面仍远低于全球平均水平。此外，相较于拥有大部分生物创新技术和专利的西方发达国家，我国在该领域存在着差距的技术创新、科研成果转化率以及产业化能力，这也制约着我国生物医药产业的发展。对此，为突破瓶颈、加快生物医药产业发展并造福人民，2022 年 5 月 10 日国家发展改革委正式印发《“十四五”生物经济发展规划》（以下简称《规划》）。

《规划》中明确指出，“十四五”时期国家不仅需要持续关注生物医药的创新，还要在此基础上实现关键核心技术突破、生物产业创新平台竞争力增强、创新产品和服务对生物产业增长贡献率显著提高的更高要求，以求打造国家生物医药技术战略高科技力量，从而实现自立自强。

1.1.2 生物医药研发现状

生物医药产业主要由生物技术产业与医药产业共同组成，其中医药产业的两大支柱分别为：制药产业、生物医学工程产业。目前制药产业中，新药研发普遍存在三大问题：研发周期长、研发成本高、失败率高。据塔夫茨药物研发中心统计，各国新药物研发平均费用为 28.7 亿美元，平均研发时间为 116 个月（约为 10 年），但成功率仅为 11.83%。从理论研究到产业开发再到临床应用，药物需要经过靶点确认、先导物发现和优化、临床前开发、临床试验 I、II、III 后才能上市。只要一步失败，整个开发过程就有失败的风险。

新药物的研发是一个高消耗的过程。由于对药物标靶和相关反应识别的不准确性，在进入 I 期临床试验的药物中，只有 10% 会被批准，其余的药物会由于高毒性或无效而被淘汰；而在肿瘤学领域，进入 I 期临床试验的药物化合物仅有 5% 最终会被批准使用，远低于其他疾病领域。药物临床实验的高失败率和药物研发的复杂性使得新药物的研发周期被不断延长，图 1.1 展示了 268 种药物的研发周期。图 1.1 的统计结果显示，一种新药物的平均研发周期为 8.1 年，大多数药物的研发周期为 4.6-11.9 年，个别药物的研发周期甚至超过了 20 年。药物研发的长周期性导致药物研发的成本投入不断加大，相关研究表明，一种新药物的总研发成本平均为 2-30 亿美元。尽管研究人员投入了大量的时间、财力和物力，但是成功研发的新药物数量并没有得到有效的增长。据 FDA 的相关报道，其药物评估与研究中心（Center for Drug Evaluation and Research, CDER）在 2021 年共批准了 50 种新型疗法，包含 36 种新分子实体和 14 种生物制品，低于 2020 年的 53 种。在过去 10 年中，CDER 平均每年仅通过 24 种药物，如图 1.2 所示。由此可见，传统药物研发是昂贵、费时和困难的。




图 1.1 268 种药物研发周期的统计分析




图 1.2 1993-2021 年 FDA 批准药物数量

鉴于传统药物研发的高成本、高损耗率和长周期性，Ashburn 和 Thor 在 2004 年首次提出了药物重定位技术，即为已经批准的药物寻找新的适应症和靶点，以发现药物新的治疗疾病。药物重定位技术有效的填补了传统药物研发效率低下的空白。药物重定位方法的主要优点是，对于现有的药物来说，不仅具备了临床信息，而且还区别了临床概况（药物动力学、药效学和毒性），从而降低了研发风险。因此，该药物化合物可以迅速进入后期临床试验，降低药物研发的时间。由于这些药物的安全性已经在其他应用的临床试验中进行了测试，因此利用旧药物来治疗新疾病可以比开发新药物更快，同时可以更大程度的降低研发成本。在美国，约有 30% 的新批准药物是重新定位的药物，表 1.1 展示了部分重新定位的药物。综上，目前药物重定位技术已成功应用于医药研发领域，如抗癌药物的发现、COVID-19 的防治和罕见病治疗药物的研发等。

药物重定位研究主要包含预测未知的药物-靶点和药物-疾病之间的相互作用关系。利用深度学习技术，挖掘组学数据中的潜在关联关系，为药物重定位研究的发展提供新的动力。但是组学数据来源广泛、信息复杂，目前的药物重定位研究方法缺少对药物结构信息的挖掘和对数据来源、类型的区分，导致药物结构信息和组学数据中关键信息的丢失，已经无法满

足当前药物重定位研究的需求。所以如何利用算法适应多组学数据，挖掘药物的结构信息和异构网络中的关键信息，对药物-靶点和药物-疾病之间的相互作用关系进行准确预测成为药物重定位研究的关键问题。

表 1.1 部分成功的重定位药物

药物名称	作用机制	原适用症	新适用症
丁氨苯丙酮 (Bupropion)	去加肾上腺素增强剂	抑郁症	戒烟
氯丙嗪 (Chlorpromazine)	多巴胺受体阻滞剂	抗催吐/抗组胺 剂	非镇静安定剂
度洛西汀 (Duloxetine)	非选择性 5-羟色胺 重摄取抑制剂	抑郁症	压力性泌尿失禁
氟西汀 (Fluoxetine)	非选择性 5-羟色胺 重摄取抑制剂	抑郁症	月经前心境恶劣
加兰他敏 (Galantamine)	乙酰胆碱酯酶抑制剂	脊髓灰质炎 卒中 麻木	轻到中度阿尔茨 海默症
米诺地尔 (Minoxidil)	β 加肾上腺素增强剂	高血压	脱发
帕罗西汀 (Paroxetine)	非选择性 5-羟色胺 重摄取抑制剂	抑郁症	社交焦虑症 强迫症 外伤性压迫症
雷洛昔芬 (Raloxifene)	cGMP 磷酸二酯酶	乳腺癌 前列腺癌	骨质疏松症
昔地那非 (Sildenafil)	5 (PDE5) 抑制剂	心绞痛	勃起功能障碍

1.2 市场分析

1.2.1 宏观分析

(1) 政策环境 (Policy)

在政策方面，国家发展改革委员会于 2022 年 5 月 10 日正式印发《“十四五”生物经济发展规划》（以下简称《规划》）。《规划》中明确指出“十四五”时期国家的发展目标，描绘了未来十几年我国人工智能发展的宏伟蓝图，确立了“三步走”目标：到 2020 年人工智能总体技术和应用与世界先进水平同步；到 2025 年人工智能基础理论实现重大突破、技术与应用部分达到世界领先水平；到 2030 年人工智能理论、技术与应用总体达到世界领先水平，成为世界主要人工智能创新中心。《规划》指出以提升新一代人工智能科技创新能力为主攻方向，以加快人工智能与经济社会国防深度融合为主线，按照“构建一个体系、把握双重属性、坚持三位一体、强化四大支撑”进行总体布局，确定了建立开放协同的人工智能科技创新体系、培育高端高效的智能经济、建设安全便捷的智能社会、强化人工智能对国家安全的支撑、构建泛在安全高效的智能化基础设施体系、实施新一代人工智能重大科技项目等六方面的重点任务。

与此同时，《规划》计划将加快发展生物技术和生物产业，到 2025 年让生物经济成为推动高质量发展的强劲动力，同时不断加强生物安全风险防控和治理体系建设，强调需要加快提升生物技术创新能力，开展前沿生物技术创新，打好关键核心技术攻坚战。同时，随着近年来我国医药行业发展，对药物研发市场整体需求增加，国家对医药合同开发和生产组织的

发展保持了乐观态度，并且提供了许多政策支持，如：2021 年 10 月，国家卫生健康委员会发布的关于印发《“十四五”国家临床专科能力建设规划》的通知提到要坚持技术创新的发展思路，加强临床诊疗技术创新、应用研究和成果转化，特别是再生医学、精准医疗、生物医学新技术等前沿热点领域的研究，争取在关键领域实现重大突破。这也为后续医药技术研究与发展、新药开发与旧药重定向提供了强大的政策支持。

(2) 经济环境 (Economic)

在经济方面，中国人工智能市场规模在 2016 年-2020 年持续增长，市场规模从 2016 年的 154 亿元增长至 2020 年的 1280 亿元，年复合增长率达到 69.79%。2020 年中国人工智能行业核心产业市场规模为 1513 亿元，同比上涨 38.93%，带动相关产业市场规模为 5726 亿元，同比上涨 49.82%。在新产业、新业态、新商业模式经济建设的大背景下，企业对 AI 的需求逐渐升温，人工智能产值的成长速度令人瞩目，预计到 2025 年人工智能核心产业市场规模将达到 4533 亿元，带动相关产业市场规模约为 16648 亿元。随着新基建产业愈发受到国家重视，人工智能产业未来将持续增长，预计 2022 年将达 2729 亿元。

同时，我国医药市场仍存在较大发展空间。艾昆纬数据显示，以生物药为例，过去十年，全球生物药销售额年复合增长率高达两位数，相较小分子药物，其市场份额显著提高。我国生物药市场规模虽然在 2019 年首次突破千亿元人民币，但 2020 年在总体医药市场中占比仅 14%，远低于发达国家和地区占比 20%~40% 的水平。据艾昆纬统计，2021 年我国新药研发投入高达 220 亿美元，占全球药物研发支出的 11%，2022 年我国新药研发投入将会达到 280 亿美元，占全球药物研发支出的 12%，预计未来仍将保持增长态势，增速也将远超全球平均增速。根据 Frost & Sullivan 的报告，全球 CDMO 市场 2020 年规模为 3823 亿元，从 2016 年到 2020 年全球 CDMO 市场年复合增长率 11.93%，预计 2021-2025 年全球 CDMO 市场年复合增长率将达到 13.79%，2025 年全球 CDMO 市场将达到 7369 亿元，全球 CDMO 市场未来空间巨大。同时艾昆纬数据显示，目前我国 CDMO 市场主要由小分子药物占据，占比约 80%；生物制剂以及基因/细胞疗法 CDMO 将保持 25%~30% 左右的高速增长，未来比例有望提升，总体来看 CDMO 在我国呈现出高速发展态势。

(3) 社会环境 (Society)

在社会层面，随着我国国民经济的飞速发展以及人民生活水平的不断提高，居民可支配收入的提高，居民的健康意识不断加强，人们更加重视日常身体健康的维护以及疾病的治疗，我国居民每年在医疗保健方面的支出也在不断上升。艾媒咨询数据显示，2014-2019 年中国居民人均消费支出和人均医疗保健消费支出呈现同步增长的态势，2019 年中国居民人均消费支出达 21559 元，人均医疗保健消费支出达 1902 元。虽然 2020 年受疫情影响，人均居民消费支出略有下滑，但依旧超过了 21000 元。并且，随着人们对健康的关注度和需求度的逐渐上升，大健康产业已经成为全球热点和新的经济增长点。艾媒咨询数据显示，2014 到 2021 年，中国大健康产业整体营收保持稳定增长，2021 年营收规模达 8.0 万亿元，增幅达 8.1%，预计 2024 年将达 9.0 万亿元。同时 2021 年中国老年群体的主要消费中健康消费占比高达 40.9%，中国与全球的大健康产业发展情况基本一致，同样由于社会结构变化而需求不断增长，具有可持续增长性。

人工智能引发第四次工业革命，自从人工智能自诞生以来，亦开始与各类行业深度融合，成为经济结构转型升级的新支点。目前人工智能已经在 GPU、人脸识别和无人驾驶等各个领域得到了快速的应用。在制造业方面，未来汽车行业的研发设计、供应链运输、驾驶技术的提供以及交通的解决方案等将有人工智能的参与。服务业也同样广泛应用受益于人工智能技术的发展应用，医疗保健行业是受益於人工智能的另一主要服务业。根据世界银行数据，全球医疗保健开销占全世界 GDP 的 10%，而其中至少 10%(约千亿美元)用于如癌症检测和 X 光片检查等的医疗手段诊断。乃至通过机械手臂做一些高难度的手术，例如上海的中山医

院的的心脏外科就有叫“达芬奇”的机械手臂为病人做手术。相较于人力而言，人工智能技术更加精确安全，成功率更高。相信在不远的未来人工智能技术将会帮助提升基层医院进一步提升诊断速度，准确程度和治疗精度。

(4) 技术环境 (Technology)

在技术层面，未来五年，我国医药产业发展机遇与挑战并存，当前我国新药研发与全球差距正逐步缩小，但靶点扎堆、适应症集中等问题仍然存在。与此同时，外资药企不断将新药引入我国医药市场，在竞争加剧的同时，将有利于我国医药产业的加速创新升级。当前医药产品主要分为制药和医疗器械，其中，制药分为化生药、中药和生物药；医疗器械分为高值医用耗材、低值医用耗材、医疗设备以及体外诊断(In Vitro Diagnosis, IVD)。就药品研发而言，一款药物的研发制造起始于药物发现阶段，需要从数量高达 10000 以上的化合物中筛选潜在先导化合物，整个阶段总体成功率仅 51%。在经历了临床前、临床试验与上市审批等阶段后，最终可能会有 1 个上市药品，整体至少耗时 10 年，总投资超过 10 亿美元。时间长、成本高、研发成功率低，这些痛点制约药企研发生产进度，挫伤积极性。就医疗器械而言，我国医疗器械行业痛点广布，多集中于密集技术型产品，广泛分布在原材料供应商、医疗器械制造商、科研机构/院校研究所以及市场终端。从现状看，行业内如低值医用耗材，因其具有较低技术壁垒故行业发展较为成熟，可基本实现自给自足；但高值医用耗材等高技术性产品，原材料多依赖进口，且需要复合型专业人才避免试错成本的增加，提高试验准确率。

但随着 AI 技术的不断发展，“互联网+”融入各行各业，药品研发也在计算机技术的帮助下不断升级。其中，药物发现、目标靶点选择、亲和力预测等药品研发和重定位的前期工作，通过计算机进行智能筛选与虚拟实验，可以很好地帮助研发人员预先确定成功率较高的选择，从而极大地缩短了实验发现的过程，提高生物实验效率，进而降低研发成本与临床失败的风险。根据中国科学技术信息研究所发布的《2021 年中国科技论文统计报告》，2021 年中国卓越科技论文总体产出持续增长，国际顶尖期刊论文数量排名世界第 2，其中热点论文数为 1515 篇，占世界总量的 36.3%，数量比 2020 年增加了 10.2%。最近 10 年 (2011-2021 年) 我国高被引国际论文榜单被临床医学霸榜，前十名中有 7 篇临床医学论文，且前三甲均被临床医学论文占据，这也说明中国在医学领域科研水平已经达到国际顶尖水平。同时报告中还显示，2020 年中国卓越科技论文共计 46.38 万篇，其中，卓越国际科技论文 21.60 万篇，卓越国内科技论文 24.78 万篇，最多的学科为临床医学、化学、电子信息、通信与自动控制、生物学。临床医学、化学、电子信息的不断发展，也为现代化科技制药提供了强大的技术支持。

从整体宏观来看，智能医药行业正迎面走向时代的浪潮，在政策、经济、社会、技术的推动下，智能医药行业仍具有大量的发展空间。

1.2.2 微观分析

本节主要对项目与团队本身进行微观上的分析，以此来判断自身能力与能够解决的社会问题。

(1) 优势 (Strengths)

本项目依托大学计算机与人工智能学院，经过多年建设，形成了从本科到博士研究生教育的完整培养体系。学院学术梯队结构合理，师资力量雄厚。

(2) 劣势 (Weaknesses)

本项目主要依托大学计算机与人工智能学院研究生的研究与实践进行发展，专业人才培养需要花费较长的时间，且由于升学、就业等相关因素，相关团队人员迭代速度快。与长期处于同行业的专业一体化公司相比，团队在人员培养、人才流动上存在一定劣势。

(3) 机会 (Opportunities)

“十四五”期间国家政策将会大力支持“新医药”行业的发展，并且 CDMO 行业已经在国内市场取得初步成功。随着“人工智能”+“生物医疗”相关技术的逐渐成熟，团队研发可参考的理论模型较多，大大降低了新理论模型的论证与研发时间。同时，调查发现当前中国医药领域与大健康领域市场前景广阔，随着中国经济的高速发展与社会整体教育水平上升，越来越多的人开始关注身心健康。宏观来看，发展生物医药满足国家发展需求，符合社会未来趋势。

(4) 威胁 (Threats)

当前医学信息学进行算法研究与测试主要使用互联网公开的经典数据集，虽然经典数据集具有行业代表性、能够进行模型比对、模型优势证明等独特优点，但数据库可能存在更新时间缓慢、数据年代久远等因素，导致模型无法对实际运用效果进行准确评估。同时，由于存在硬件计算力不足等客观因素限制，所以项目整体仍具有待改进空间。

1.3 需解决的问题

基于以上分析，本节将会对传统生物医药行业所面临的问题进行总结。

统计结果显示，一种新药物的平均研发周期为 8.1 年，大多数药物的研发周期为 4.6-11.9 年，个别药物的研发周期甚至超过了 20 年。药物研发的长周期性导致药物研发的成本投入不断加大，一种新药物的总研发成本平均为 2-30 亿美元。同时由于对药物靶标和相关反应识别的不准确性，在进入 I 期临床试验的药物中，只有 10% 会被批准，其余的药物会由于高毒性或无效而被淘汰；而在肿瘤学领域，进入 I 期临床试验的药物化合物仅有 5% 最终会被批准使用，远低于其他疾病领域。

当前传统医药行业存在以下问题：

- 药物研发周期时间长，药物研发成本高
- 药物靶标和相关反应识别准确率低
- 药物疾病相互作用机制不清晰，数据区分度低

1.4 研究目标

为了帮助传统医药行业利用人工智能技术实现产业升级，项目团队从社会宏观因素出发，基于团队自身优势与技术，致力于完成以下几个目标：

- 提高药物研发效率，降低药物研发成本
- 基于人工智能技术提高药物-靶点相互作用预测的准确率，降低药物研发成本并为已批准的药物寻找新的适应症和靶点
- 采用异构邻域图网络实现对组学数据的区分和信息捕获，提升对多组学数据中关键信息的提取和在药物发现中的泛化能力，探索以现有药物新的可治疗疾病

1.5 应用价值

本团队基于图神经网络所提出的药物发现方案属于新工科人工智能技术，具有低成本和高通量的特性，能够高效对药物靶标和作用疾病进行预测，降低了药物研发周期，为发现药物的新适应症指明了方向。我们的方案为人工智能与制药行业交叉应用提供了重要实例，助力药物研发。

1.5.1 学科交叉应用实现医药产业升级

目前大多数药物都是通过与患者体内的特定靶标相互作用来发挥其治疗作用。明确药物作用靶点和作用机制，对于药物研发和重定向至关重要。药物靶标可以通过生物实验（例如蛋白质组学质谱法）进行识别，但受实验规模、精度和费用等因素的制约，大规模的生物实验通常难以广泛应用。而团队设计模型属于基于新工科人工智能技术的药物疾病预测方法，其具有低成本和高通量的特性，除了能够高效进行药物疾病预测，降低药物研发周期，还能对治疗药物进行识别，以此加深我们对药物的作用机制、代谢、不良反应和耐药性的理解，

为发现药物的新适应症指明方向，帮助降低药物研发的成本。

1.5.2 助力国家科技创新

本团队提出的模型实现了全国产化，这对于打破国外的技术封锁，提高我国人工智能在医药行业发展能力有着重大意义，本产品的出现也将会增强科研人员的信心，提高科研人员的积极性，从而助力科技创新和技术发展。当前人工智能技术已受到众多大型制药公司青睐，在 2022 年，制药行业通过采用人工智能技术使收入增至 21.99 亿美元。但是制药行业也需要深入了解人工智能带动产业发展的潜力，并清楚其可以实现的合理目标。本团队所设计的模型为人工智能与制药行业交叉应用提供了重要实例，能够更好地帮助制药行业了解人工智能技术为行业发展带来的动力与前景。

1.5.3 打破专业壁垒，增加就业机会

就药品研发而言，一款药物的研发制造起始于药物发现阶段，需要从数量高达 10000 以上的化合物中筛选潜在先导化合物，整个阶段总体成功率仅 51%。如果一个非生物专业领域人士来进行传统生物实验，那么除了研发成本，还可能产生一些额外的、非必要的器材、药品损失，导致企业研发成本增加。数据显示，2020 年，中国医药市场在药物研发总投入为 247 亿美元，占全球药物研发支出的 12.1%。预计到 2025 年，中国在药物研发支出将达到 496 亿美元，年均复合增长率为 15.0%，约是全球同期水平的 2 倍。由于传统的新药研制方法难度越来越大，研制开发成本不断上升，成功率越来越低，所以传统的生物方法实验必须由其相关领域的专业人才进行。但是专业领域人才培养需要极大的时间、财力付出，如果所有实验都采用领域内专业人才则有可能导致“大材小用”，造成人力资源浪费。

本团队所设计的模型，主要采用了融合多层图信息的 Transformer 网络。特征提取和关系预测等相关工作都可以向用户透明化，在模型内部进行计算与解决。使用者只需要将相关药品数据、靶点数据和疾病数据等输入模型即可获取到预测结果。由此，当模型普及后，大型一体化制药公司也能够聘请非专业人才进行药物-靶点相互作用、药物-疾病相互作用预测，从而基于相关预测结果帮助专业人才提高实验成功率，降低成本。在未来，团队也将尝试与百度网讯科技公司及飞桨 PaddleHelix 平台在生物计算方向上进行深度合作，在新药研发、药物重定位领域，预计可间接带动企业就业人数达 1000 人。

二、设计思路与方案

2.1 药物重定位研究现状

目前, 药物重定位研究主要包含药物-靶点相互作用(Drug-Target Interaction, DTI)预测和药物-疾病相互作用(Drug-Disease Interaction, DDI)预测, 生物组学数据的积累为药物重定位研究提供了丰富的数据, 所以如何利用组学数据, 探索药物与靶点和疾病之间的相互作用关系是药物重定位研究的热点问题。在目前主流的药物重定位研究方法中, 表 2.1 列出了近年来一些经典的药物重定位研究方法。

表 2.1 药物重定位主流研究方法汇总表

方法名称	方法类别			任务类型			提出时间
	机器学习	深度学习	图神经网络	DTI 预测	DDI 预测	其他	
PREDICT	✓				✓		2011
MultiviewDTI	✓			✓			2017
DRRS		✓			✓		2018
DeepConv DTI		✓		✓			2019
Deep Purpose		✓		✓			2020
DeepCDR		✓				✓	2020
MolTrans		✓		✓			2021
AEFS		✓		✓			2021
DTI-CDF		✓		✓			2021
HyperAttention DTI		✓		✓			2022
NeoDTI			✓	✓			2019
GFPPred			✓		✓		2021
GraphDTA			✓			✓	2021
LAGCN			✓		✓		2021
HINGRL			✓		✓		2021
DRHGCN			✓		✓		2021
KGDTI			✓	✓			2022
CTST			✓		✓		2022

2.1.1 药物-靶点相互作用预测研究现状

已应用于药物-靶点相互作用预测的机器学习方法主要包括基于相似性的方法和支持向量机 (Support Vector Machines, SVM) 等方法。基于机器学习方法的药物-靶点相互作用研究可以追溯到早期基于药理学的 DTI 预测。基于相似性/距离的方法曾经是药物重定位研究的热点方法, 该类方法基于药物相似性、基因相似性和关联关系网络来定义相似度函数。Zhang 等人提出了 MultiviewDTI 的方法, 并通过整合药物数据、靶点化学数据和已知的 DTI 数据, 提升了对 DTI 预测结果。SVM 应用方法灵活, 可对特征矩阵进行有效的处理。Napolitano 等人通过将分子靶标、药物化学结构和基因表达相似性作为输入特征, 利用 SVM 方法来预测药物治疗类别。他们将输入特征合并到药物相似性矩阵中, 并将合并后的矩阵作为 SVM 分类的主要依据。基于机器学习的 DTI 预测方法有效的提取了规则化数据中的特征信息, 同时由于该类模型架构简单、参数量较小, 有效的避免了计算资源的消耗。但是, 该类方法无法有效提取复杂数据中的信息, 并不适用于目前的大规模组学数据。

与机器学习相比, 深度学习拥有更复杂的模型结构和更强大的特征提取能力。深度学习方法可以对药物和靶点序列结构中的信息进行挖掘, 捕获药物和靶点的特征信息, 在大型数

据集中能够发现潜在的复杂结构信息。目前,深度学习技术被广泛的应用到药物重定位研究中。研究者从药物化学结构、靶点序列结构和药物-靶点作用网络等方面入手,展开了一系列相关研究。

针对药物化学结构信息,DeepPurpose 框架整合了多种 DTI 预测方法,并在多个数据集上表现出了较好的性能。为保持药物化学结构和功能的一致性,Sun 等人提出了一种基于自编码器的方法(AEFS),在空间一致性约束下进行预测 DTIs。相关实验结果证明,AEFS 通过保持药物原始特征和嵌入特征在标记空间中的相关性分布,保持了药物的化学性质和功能之间的一致性。Nguyen 等人采用与其他研究者截然不同的研究思路,他们以药物分子图作为药物的表示形式,并提出了用于药物-靶点亲和力预测的 GraphDTA 模型。实验结果表明图神经网络可以进一步提升药物-靶点亲和力的预测效能。除了药物的化学结构,靶点的序列结构中同样存储了大量的特征信息。针对于靶点序列结构中的残基信息, Lee 等人使用基于卷积的操作有效提取了相关特征,并提出 DeepConv-DTI 方法。DeepConv-DTI 将获取的信息用于药物-靶点关系预测。实验结果表明该模型可以提取到靶点序列中的残基信息。Wang 等人使用 DeepLSTM 模型进行 DTI 预测,采用 PSSM 和 LM 模块来提取靶点的进化特征,并与分子指纹相关联,采用 SPCA 进行压缩。实验结果表明他们提出的方案在特征方面提取优于 Wang 等人的方法。

在药物-靶点相互作用网络中, Yang 等人提出基于多头注意力机制和位置感知的相互学习机制。在进行 Orphan-Target 和 Orphan-Drug 预测时,模型性能显著高于当时的主流方法,表明他们提出的方法提高了 DTI 建模的概括性和解释能力。在注意力机制的作用下,HyperAttentionDTI 整合了药物和靶点之间的作用关系,进行 DTI 的预测。Li 等人通过整合药物化学结构相似性、常见药物靶标及其相互作用构建了药物相似性对,并在此基础上设计了一种双向网络,进行 DTI 预测和药物潜在适应症的预测。以上基于深度学习的方法在药物-靶点相互作用预测上表现出了较好的结果,但是对于具有复杂关联关系的组学数据,基于深度学习的方法却很难学习到不同实体之间的复杂关系,从而缺乏对药物再利用的实际指导意义。

图神经网络的提出和快速发展,为药物-靶点相互作用预测提供了有力的技术保障。图神经网络可以有效的提取不同实体之间复杂的拓扑结构信息,进而提升药物-靶点预测结果对药物重定位研究的实际指导价值。

基于图神经网络的药物-靶点相互作用预测研究主要通过构建异构网络的方式进行。Wan 等人提出了 NeoDTI,该模型整合了异构网络数据的信息来进行药物-靶点关系预测。结果表明,NeoDTI 可以为药物开发和药物重定位提供一个稳健的工具。Zhou 等人构建了一个包含 139760 个药物-副作用对的异构网络,进行药物-靶点的相互作用预测,从而发现药物新的适应症。Chu 等人提出了 DTI-CDF 方法,该方法可以在异构网络中提取药物之间的多种相似性和靶点之间的相似性特征,并将捕获的特征信息用于药物-靶点关系预测。在相关数据集上,DTI-CDF 方法的性能优于集成学习方法和一些深度学习方法。Li 等人提出了基于感应矩阵和异构图注意网络的方法(IMCHGAN)来预测 DTIs。IMCHGAN 采用了两级神经注意机制的方法,分别从异构网络中学习药物和靶点的潜在特征表征并输入归纳补全矩阵得到最终的 DTI 评分。基于图神经网络的药物-靶点相互作用预测方法虽然可以有效的提取药物和靶点之间复杂的拓扑信息,但是该类方法仅考虑了药物和靶点之间的关联关系,而忽略了两者的本身的结构信息,从而在一定程度上也限制了其实际应用的价值。

2.1.2 药物-疾病相互作用预测研究现状

在药物重定位研究中,另外一种主要任务是药物-疾病相互作用关系预测。在早期,研究者主要基于相似性的方法进行 DDI 预测,随着高通量技术和生物信息学方法的进步,研究者正致力于采用知识图谱和图神经网络来解决药物-疾病相互作用关系的预测问题。

在早期,研究者基于相似性理论和 Logistic 回归提出了 PREDICT 框架。在 PREDICT 框架中,将药物之间的相似性特征与疾病之间的相似性特征相结合,并以综合相似值作为特征,利用逻辑回归预测相似疾病的相似药物。

在信息爆炸增长和生物医学快速发展的今天,知识图谱为不同医学实体(如药物、疾病等)之间的相互作用提供了一般性和普遍性的展示,目前已经成为药物-疾病相互作用关系预测中不可缺少的一项技术。基于知识图谱和图嵌入的方法在药物-疾病相互作用预测任务中得到了广泛的关注。在药物和疾病构成的知识图谱中,我们可以很好地计算它们的相似性,从而识别特定疾病的有效治疗药物。Sosa 等人从生物医学文献中构建了一个关于药物、疾病、基因和蛋白质的医学知识图谱,并使用图嵌入技术来预测药物和疾病之间的联系。Gysi 等人开发了一种基于图神经网络的方法,并以 SARS-CoV-2 为研究案例,并确定了 81 种有潜在用途的药物。Zhang 等人使用 PubMedBERT 方法从 PubMed 等研究文献中,提取了以 COVID-19 为重点的语义要素并构建了知识图谱,采用 TransE 方法进行知识表示。实验表明他们的方法对候选药物的筛选和产生机制是可行的,并可以推广到其他疾病的潜在药物发现。Chen 等人基于知识图谱,提出了融合多类型特征的药物-疾病关联关系预测模型(MUFFIN)。MUFFIN 模型采用双极交叉的策略,从知识图谱和药物分子结构图中捕获药物的特征信息,在一定程度上减轻了深度学习模型对标记数据的依赖性。基于知识图谱和图嵌入表示的方法可以有效捕获实体间的关联关系,但不可忽视的是,基于知识图谱的 DDI 预测方法缺乏对数据差异性的考虑。

在多来源组学数据中,生物系统中的分子相互作用可以通过图神经网络来建模。在这些模型中,网络节点代表药物、疾病或基因产物,而边则代表节点之间的相互作用或关系。以往的研究表明,药物-靶点网络、药物-药物网络、药物-疾病网络、蛋白质相互作用网络、转录网络和信号网络对确定药物和疾病之间的作用关系具有重要作用,从而为药物的发现或药物重定位提供了新的机会。Li 等人最近建立了一个因果网络来识别现有药物的新治疗用途。在因果网络中,每个链的转换可能性是根据已知的药物-疾病治疗关联来估算的。

药物重定位的一个主流方法是通过构建包含不同类型医疗实体(如疾病、药物和蛋白质)之间关系的异构网络预测现有批准的药物和疾病之间的新联系。Wu 等人将网络聚类应用于药物-疾病异构网络,以识别紧密相连的疾病和药物模块,这些模块可用于提取可能的药物-疾病对以达到药物重新定位的目的。在网络中,两个节点与共享的基因/靶点及其丰富的特征连接起来,并通过 Jaccard 评分对连接进行加权。Gao 等人设计了提取和集成异构网络和子网络中拓扑结构的模型(CTST),进行药物-疾病关联关系预测和药物重定位研究。在药物和疾病构成的异构网络中,CTST 利用图自动编码器和特征级注意力机制自动学习节点之间的拓扑关系。相关实验证实了 CTST 具有发现潜在候选疾病的能力。Yu 等人在 DDI 预测任务的研究中基于层次感知和注意力思想提出了 LAGCN 方法。LAGCN 基于相似性网络和关联关系网络构建了异构网络,并基于 GCN 对异构网络中的信息进行学习,以获得药物和疾病的特征表示。

在以上研究中,不同来源和类型数据被不加区分的整合在同一个异构网络中,造成了网络中特定信息的大量丢失。Zhao 等人提出了一种新的基于异构信息网络模型(HINGRL),以基于图表示学习技术精确识别药物的新适应症。HINGRL 应用不同的表示策略,从拓扑学和生物学角度学习异构网络中节点的特征,并使用随机森林分类器预测未知的 DDI。HINGRL 提供了一种识别药物-疾病关联的新视角,并可以对新疾病进行识别。DRHGCN 对来自不同域的数据分别使用域内和域间特征提取模块提取异构网络中的特征信息,用于预测 DDI。但是在实际工作中,DRHGCN 依赖于药物和疾病的先验知识,这导致 DRHGCN 并不适用于所有新的疾病。Cui 等人提出了用于乳腺癌药物重定位的 GraphRepur 方法。该方法收集了差异表达基因、药物基因表达数据和药物之间关联关系,通过提取药物关系中包含

的药物特征和拓扑信息,实现对乳腺癌的药物重定位。但是 GraphRepur 依赖于负样例数据,不适用于孤儿药 (Orphan Drugs) 的发现。

基因组学、蛋白质组学等组学数据的积累,为基于图神经网络的药物重定位研究提供了丰富的数据来源,同时,图神经网络可以有效的提取多来源数据中的拓扑信息,有效的促进了药物-疾病相互作用关系预测的发展。目前基于图神经网络的方法已成为药物-疾病相互作用关系预测研究中的热点。但是,大多数基于图神经网络的方法缺乏对数据来源和类型的区分。这意味着不同来源和类型的数据被不加区分的混合在一起,导致数据中关键信息的丢失。虽然目前一些基于异构网络的方法对数据进行了区分,但是这些区分是有限的,并且在实际应用中缺乏对数据域之间信息的交互,导致该类模型捕获数据特征不充分,限制模型的性能。

2.2 设计思路

本团队基于图神经网络提出图信息融合 Transformer 网络和异构邻域网络用于药物发现。



图 2.1 项目整体设计思路

基于图信息融合的 Transformer 网络用于药物-疾病关系预测, 主要包含数据表示、药物特征提取、靶点特征提取和关系预测四个部分。主要设计思路为: (1) 将药物 SMILES 序列表示为图结构并填充为固定大小的药物分子结构图, 采用随机初始化方式获得靶标的序列嵌入矩阵表示; (2) 采用 GCN 捕获药物分子的结构信息, 将 GCN 隐藏层的信息输入到 Transformer 网络以克服其对边特征学习的不足; (3) 针对靶标的常序列的问题, 采用 CNN 来提取靶标序列中的残基信息; (4) 采用全连接神经网络进行关联关系的预测。




图 2.2 Deep MGT 系统概述

基于邻域对比学习异构图神经网络用于药物-疾病关联关系预测, 主要包含异构网络构建、编码器和解码器三个部分。主要设计思路为: (1) 基于相似性网络构建药物-疾病关系异构网络; (2) 针对缺乏对数据类型区分和数据域之间信息交互的不足, 设计单邻域和多邻域特征提取模块分别提取相似性网络和异构网络中的特征信息, 采用对比学习和注意力机制并行融合邻域特征, 提升对特征信息的精细化区分; (3) 采用全连接网络进行关系预测。




图 2.3 HNNCL 系统概述

2.3 技术路线

2.3.1 基于图信息融合的 Transformer 用于药物-靶点相互作用预测

药物-靶点相互作用在药物重定位研究中具有关键作用。基于计算的 DTI 预测方法可以极大的缩短 DTI 验证时间,有效的降低研究成本。互联网技术的迅速发展,为基于深度学习和图神经网络的药物-靶点相互作用预测方法提供了数据积累,但是目前基于深度学习和图神经网络的 DTI 预测方法仍存在以下问题:

(1)基于图神经网络的方法更加注重节点信息的捕获,缺少对网络中边的特征学习,导致缺乏对节点之间关系信息的捕获;

(2)基于字符串形式的表示方法难以捕获药物分子中的关系信息,造成药物原子之间相互作用信息的丢失;同时,字符串形式的序列表示方法非常脆弱,字符串的改变极易引起分子化学结构的改变,不利于存储和研究。

针对以上 DTI 研究中存在的问题,本研究提出了一种融合多层图信息的 Transformer 网络(Transformer Network Incorporating Multilayer Graph Information, Deep MGT),以捕获参与 DTI 预测的药物化合物的分子结构信息。Deep MGT 主要包含三部分:药物特征提取、靶点特征提取和关系预测。在药物特征提取模块中,将药物的 SMILES 字符串序列表示为药物分子图,克服了 SMILES 序列脆弱性的缺点;通过使用图卷积神经网络来捕获药物化合物分子结构中原子的特征信息,最大程度的提取了药物化合物分子结构中的原子信息;同时将图卷积神经网络中不同隐藏层中的信息输入到改进多头注意力机制的 Transformer 网络中,捕获来自图卷积神经网络中不同层级的信息,更深层次的挖掘药物分子结构中不同原子之间的相互信息,克服图卷积神经网络对边特征学习欠缺的缺点。在靶点特征提取模块中,对于靶点的序列结构,使用卷积神经网络来捕获靶点序列中局部残基信息,有效的提取了靶点的特征信息。在关系预测模块中,使用全连接神经网络进行 DTI 关系的预测。

2.3.2 基于邻域对比学习异构图神经网络药物重定位模型

组学数据的积累,为基于计算的药物重定位研究提供了新的发展前景。但是,目前的药物重定位研究缺乏对数据类型的区分和数据域之间信息的交互,这导致模型对数据特征学习不充分和数据中关键信息的丢失,在实际应用中依赖先验知识,导致模型泛化能力较差。因此,设计能够自动学习邻域特征并具有广泛适用性的药物定位方法至关重要。

针对传统方法缺乏对数据的区分和异构网络缺乏对数据域信息交互的不足,本研究提出了基于邻域对比学习异构图神经网络(Heterogenous Neighborhood Networks with Contrastive Learning, HNNCL)的药物重定位方法。具体来说,针对药物-药物相似性网络、疾病-疾病相似性网络、药物-疾病关联关系网络,本研究设计了单邻域特征提取模块(Single-Neighborhood Feature Extraction Module, SNFEM)和多邻域特征提取模块(Multi-Neighborhood Feature Extraction Module, MNFEM)。首先,将 SNFEM 用于提取药物-药物和疾病-疾病相似性网络中的特征信息, MNFEM 用于提取药物-疾病关联关系异构网络中的特征信息;然后,利用对比学习将单邻域特征和多邻域特征进行融合,同时使用三元损失,对特征信息进行更加细致的区分;最后采用注意力机制将多来源信息进行融合。进行关系预测时,将三元损失与药物-疾病关系预测损失相结合,提升模型的泛化能力,进一步降低模型对先验知识的依赖性。

2.4 设计方案

2.4.1 基于图信息融合的 Transformer 网络的设计方案

2.4.1.1 算法概述

Deep MGT 通过整合药物分子结构信息和靶点的序列特征,进行药物-靶点相互作用的预测。Deep MGT 主要包含药物嵌入表示、靶点嵌入表示和关系预测三个部分,如图 2.4 所示。




图 2.4 Deep MGT 模型结构图

Deep MGT 核心工作如算法 1 所示，将药物分子结构信息、靶点序列信息和药物-靶点作用关系作为输入，使用融合图信息的 Transformer 网络和卷积神经网络分别提取药物和靶点的特征信息。最后，将药物特征和靶点特征进行连接，并使用一个全连接神经网络进行 DTI 的预测。

算法 1: Deep MGT

输入： 药物分子特征矩阵 X
 药物分子邻接矩阵 A
 靶点嵌入矩阵 S
 药物-靶点关联矩阵 R
 最大训练迭代次数 T
 隐藏层数量 L

输出： 预测概率得分矩阵 $\hat{R}$ 。

```

1: 初始化权重矩阵  $W$ ,  $W_{drug}$ ,  $W_{tar}$ ;
2:  $t \leftarrow 1$ ;
3: 重复
4:   for  $l = 1, 2, \dots, L$ :
5:     利用公式(3.16)和公式(3.18)计算药物特征;
6:     利用公式(3.20)和公式(3.21)计算靶点特征;
7:   end for
8:   利用公式(3.19)获得药物的最终嵌入表示;
9:   利用公式(3.21)获得靶点的最终嵌入表示;
10:  利用公式(3.23)获得预测矩阵  $\hat{R}$ ;
11:  利用公式(3.25)更新权重矩阵;
12:   $t \leftarrow t + 1$ ;
13: until  $t > T$  或者公式(3.25)收敛;
14: 返回  $\hat{R}$ 。

```

2.4.1.2 药物嵌入表示

考虑到药物分子的特殊性和图卷积神经网络的局限性,本研究设计了融合多层图信息的 Transformer 网络,并将其用于药物特征的提取。融合多层图信息的 Transformer 网络主要包含分子补全图卷积神经网络和改进的 Transformer 网络两个部分,模型结构如图 2.5 所示。




图 2.5 药物嵌入表示结构图

网络以药物的分子结构图作为输入，采用分子补全图卷积神经网络（Molecular Complementary Graph Neural Network, MCGCN）进行药物分子图信息的提取，同时将 MCGCN 中每一层的特征输入到 Transformer 网络中，并在 Transformer 网络中采用不同的多头注意力机制进行特征的进一步提取。通过对 MCGCN 中不同隐藏层的特征进行进一步的提取，保留了药物分子图中原子之间边的信息，丰富了药物分子的特征，弥补了 GCN 忽略节点之间关系的缺点。

因为药物分子结构的独特性，每种药物拥有不同的分子结构，这就意味着每种药物的分子图是独一无二的。原始的图卷积神经网络旨在对单个图进行节点的分类。为了使卷积神经网络能够适应药物-靶点相互作用预测的任务，本研究使用了分子补全图卷积神经网络。MCGCN 通过为原始药物分子图增加一个补充图，来保证每个药物分子的邻接矩阵和特征矩阵大小一致，其中原始图和补充图是互相独立的。通过补全操作，MCGCN 可以用于处理不同大小和结构的药物分子。MCGCN 包含两个隐藏层，每个隐藏层之后采用 ReLU 函数作为激活函数，并在 MCGCN 的最后使用最大池化，降低数据的维度。

假定给出 N 种药物的原始图表示 $\{g_i = (X_i, A_i)_{i=1}^N\}$ ，则药物的补全图可以表示为

$\{g_i^c = (X_i^c, A_i^c)_{i=1}^N\}$ ，其中特征矩阵和邻接矩阵分别为 $X_i^c \in \mathbb{R}^{(D-D_i) \times C}$, $A_i^c \in \mathbb{R}^{(D-D_i) \times (D-D_i)}$ ，

D 表示补全后原子的数量，设置为 100。经过补全操作，药物分子图可以被表示为：

$$A'_i = \begin{bmatrix} A_i & B_i \\ B_i^T & A_i^c \end{bmatrix}, X'_i = \begin{bmatrix} X_i \\ X_i^c \end{bmatrix} \quad (1)$$

其中 $B_i \in D_i \times (D-D_i)$ 表示第 i 中药物的原始图和补全图之间的连接矩阵。 $A'_i \in D \times D, X'_i \in D \times C$ 分别表示补全之后的邻接矩阵和特征矩阵。第 i 种药物在 MCGCN 中被表示为 $f(A'_i, X'_i)$ ，其中在 MCGCN 的每一层被表示为：

$$H_i^{(l+1)} = \sigma(\tilde{M}_i'^{-\frac{1}{2}} \tilde{A}'_i \tilde{M}_i'^{-\frac{1}{2}} H_i^{(l)} \Theta^{(l)}) \quad (2)$$

其中， $\tilde{A}'_i = A'_i + I_N$ 是添加了 self-attention 的邻接矩阵， $\tilde{M}_i'$ 是 $\tilde{A}'_i$ 的权重矩阵，其中 $\tilde{M}_i'[j, j] = \sum_k \tilde{A}'_i[j, k]$ 。 $H_i^{(l)}$ 和 $\Theta^{(l)}$ 是第 l 层的卷积信号和滤波器参数。 $\sigma(\bullet)$ 是激活函数，被设定为 $\text{ReLU}(\bullet) = \max(0, \bullet)$ 。Deep MGT 进一步将 $H_i^{(l)}$ 的前 D_i 行表示为 $H_i^{(l, \alpha)}$ ，其余 $(D-D_i)$ 行表示为 $H_i^{(l, \beta)}$ ，得到 MCGCN 在各层之间的传播函数为：

$$H_i^{(l+1, \alpha)} = \sigma(((\tilde{M}_i + M_i^B)^{-\frac{1}{2}} \tilde{A}'_i (\tilde{M}_i + M_i^B)^{-\frac{1}{2}} H_i^{(l, \alpha)} + (\tilde{M}_i + M_i^B)^{-\frac{1}{2}} \tilde{A}'_i (\tilde{M}_i^c + M_i^{B^T})^{-\frac{1}{2}} H_i^{(l, \beta)}) \Theta^{(l)}) \quad (3)$$

Transformer 网络是基于注意力机制设置的，包含编码器和解码器两部分。在本研究的 DTI 预测任务中，我们的目的是使用 Transformer 网络进行特征的进一步提取，因此仅使用了 Transformer 网络中的编码器部分，如图 2.5 所示。Deep MGT 对编码器中的多头注意力机制进行了改进，使用不同的多头注意力机制对来自 MCGCN 不同隐藏层的药物特征信息进行处理。在 Transformer 网络中，Deep MGT 使用了两个不同 head 数量的多头注意力模块，head 数量分别为 4 和 6。经过多头注意力机制处理后的特征向量通过拼接操作进行连接，并送入层归一化部分，最后是全连接前向神经网络。

在 Transformer 网络中，注意力函数 Q 、 K 和 V 分别代表查询、键和值。多头注意机制通过 i 个不同的线性变换来投射 Q 、 K 和 V ，通过拼接不同的注意力结果，得到每注意力模块内的表示结果，最后通过拼接不同注意力模块表示结果得到最终的结果。该公式表示如下：

$$\text{MultiHead}_j(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_i) \quad (4)$$

$$\text{AllMultiHead} = \text{Concat}(\text{MultiHead}_1, \dots, \text{MultiHead}_j) \quad (5)$$

其中， AllMultiHead 表示对来自不同注意力模块的向量进行连接， i 表示每个注意力模块中 head 的数量， j 代表多头注意力模块的数量，设置为 2。

除了多头注意力模块外，编码器的每一层还包含一个完全连接的前馈网络和一个使用 ReLU 激活函数的两层线性变换：

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (6)$$

2.4.1.3 靶点嵌入表示

Deep MGT 使用 CNN 捕获提取靶点序列中的残基信息，提取靶点的特征信息。靶点特征提取模块结构如图 2.6 所示。




图 2.6 靶点嵌入表示结构图

靶点序列在嵌入层中，经过与原始嵌入表进行对应，会得到初始化之后的序列嵌入矩阵表示。当靶点序列长度如果小于嵌入矩阵的长度，会自动进行空标签的填充。Deep MGT 在进行靶点序列的特征提取时，使用不同尺寸的卷积核对靶点序列嵌入矩阵进行卷积操作，卷积核大小分别为 10、15、20，步长为 1。则从第 j 个氨基酸到第 $(j+WS)$ 个氨基酸，可以定义为：

$$(x * w)_j = \sum_{a=1}^{ES} \sum_{b=0}^{WS-1} w_{a,b} x_{a,j+b} \quad (7)$$

其中， WS 表示卷积核的大小。在每一个卷积层之后，Deep MGT 使用 ELU 函数作为激活函数。

$$\sigma(\alpha, x) = \begin{cases} \sigma(e^x - 1) & x < 0 \\ x & x \geq 0 \end{cases} \quad (8)$$

最后，为了提取最重要的局部特征，Deep MGT 对每个卷积操作之后的结果进行了全局最大池化，定义为：

$$MaxPooling(E_{pk}) = \max((x * w)_j) \quad (9)$$

其中， j 包含了靶点序列嵌入矩阵的所有卷积结果 Pk ，经过最大池化，Deep MGT 将序列中相互作用的氨基酸有效的进行了特征提取，最后将最大池化之后的结果送入全连接前馈神经网络中，并把全连接网络的输出作为靶点序列的最终嵌入表示。

2.4.1.4 关系预测及优化

Deep MGT 使用拼接操作来将药物分子结构和靶点序列的嵌入表示进行合并。然后将合并后的向量表示与原始标签一起输入构建的全连接层，以预测药物和靶点是否存在相互作用，并得到预测得分：

$$\hat{A} = f(H_{drug}, H_{tar}) = \text{sigmoid}(H_{drug} H_{tar}^T) \quad (10)$$

在 Deep MGT 模型中，使用二元交叉熵函数计算损失。

$$J(W, b) = -\frac{1}{n} \sum_i^n [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)] \quad (11)$$

为了防止训练过程中 Deep MGT 过拟合，我们用 L_2 范数对损失函数进行了进一步的优化，优化后的损失函数如公式(12)所示：

$$J_{L_2}(W, b) = J(W, b) + \lambda \sum_{l=1}^{L-1} \|W^l\|_2 \quad (12)$$

2.4.2 基于邻域对比学习异构图神经网络的设计方案

2.4.2.1 数据及异构网络构建

本团队从之前的相关研究中提取相应的药物-疾病关联、药物相似性和疾病相似性数据，分别为 Gottlieb 的数据集、Luo 的数据集、Liang 的数据集和 Yu 的数据集，并在四个数据集上评估了 HNNCL 的性能，四个数据集的详细信息如表 2.2 所示。其中 Gottlieb 的数据集和 Luo 的数据集中的药物信息来自于 DrugBank 数据库，疾病信息来自于 Online Mendelian Inheritance in Man (OMIM) 数据库。Liang 的数据集中的药物和疾病信息最早被应用于 Wang 等人的研究中。Yu 等人从 Comparative Toxicogenomics Database (CTD) 中收集了药物和疾病关联关系构成了的数据集。本研究中所使用的四个数据集，其药物实体数量、疾病实体数量以及药物和疾病之间的关联关系均不一致，且相互之间存在交集，具体如表 2.2 所示。

在本研究中，我们基于药物 SMILES 化学结构，利用 Chemical Development Kit[101] 计算 Tanimoto 得分来衡量药物之间的相似性矩阵 S_{drug} ，计算公式如公式 (20) 所示。疾病相似性矩阵 S_{dis} 是基于疾病表型通过 MimMiner 计算得到。

$$\text{sim}(i, j) = \frac{|S_i \cap S_j|}{|S_i| + |S_j| - |S_i \cap S_j|} \quad (13)$$

其中 S_i , S_j 分别表示药物 i 和 j 的 SMILES 序列中表达值为 1 的位置所构成的集合，则 $|S_i|$, $|S_j|$ 分别表示两条序列中含有 1 的数量。

表 2.2 本研究中使用的数据集的统计数据

数据集	药物数量	疾病数量	相互作用关系数量
Gottlieb 的数据集	593	313	1933
Luo 的数据集	663	409	2352
Liang 的数据集	598	269	18416
Yu 的数据集	763	681	3051

在本研究中，HNNCL 利用药物-药物相似性网络、疾病-疾病相似性网络和药物-疾病关联关系网络进行药物和疾病关联关系的预测。三种网络被表示为图的形式，分别为 $G_{drug} \in R^{N \times N}$ 、 $G_{dis} \in R^{M \times M}$ 和 $G \in R^{N \times M}$ ， N 表示药物的种类， M 表示疾病的种类。对于

G_{drug} ，其邻接矩阵为 $A^{drug} \in R^{N \times N}$ 。 A^{drug} 由 S_{drug} 组成，如果药物 $drug_j$ 在相似性矩阵 S_{drug} 中是药物 $drug_i$ 的 top-k 近邻，则 $A_{ij}^{drug} = S_{drug(i,j)}$ ，否则 $A_{ij}^{drug} = 0$ 。同理可得到 G_{dis} 邻接矩阵为 $A^{dis} \in R^{M \times M}$ ，如果疾病 dis_j 在相似性矩阵 S_{dis} 中是疾病 dis_i 的 top-k 近邻，则 $A_{ij}^{dis} = S_{dis(i,j)}$ ，否则 $A_{ij}^{dis} = 0$ 。对于 G ，其邻接矩阵为 $A \in \{0,1\}^{N \times M}$ 。如果药物 $drug_i$ 和疾病 dis_j 存在关联关系，则 $A_{ij} = 1$ ；否则 $A_{ij} = 0$ 。




图 2.7 四个数据集的维恩图

2.4.2.2 HNNCL 模型结构

本部分将详细介绍 HNNCL 预测药物-疾病关联关系的工作流程。HNNCL 算法流程如算法 2 所示，模型结构如图 2.8 所示。

算法 2: HNNCL

输入: 药物邻接矩阵 A^{drug} ，疾病邻接矩阵 A^{dis} ，药物-疾病关联矩阵 A ，药物嵌入矩阵 H_{drug}^0 ，疾病嵌入矩阵 H_{dis}^0 ，最大训练迭代次数 T ，隐藏层数量 L 。

输出: 预测概率得分矩阵 $\hat{A}$ 。

1: 初始化权重矩阵 W ， W_{drug} ， W_{dis} ；

2: $t \leftarrow 1$ ；

3: 重复

4: for $l = 1, 2, \dots, L$:

5: 利用公式(4.3)计算单邻域特征 $\hat{H}_s^{l+1}$ ；

6: 利用公式(4.5)和公式(4.6)计算多邻域特征 $\hat{H}_m^{l+1}$ ；

7: 利用公式(4.7)和公式(4.8)融合 $\hat{H}_s^{l+1}$ 和 $\hat{H}_m^{l+1}$ 特征嵌入；

8: end for

9: 利用公式(4.10)获得药物的最终嵌入表示 H_{drug} 和疾病的最终嵌入表示 H_{dis} ；

- 10: 利用公式(4.11)获得关系预测矩阵 $\hat{A}$;
- 11: 利用公式(4.12)更新权重矩阵;
- 12: $t \leftarrow t+1$;
- 13: until $t > T$ 或者公式(4.12)收敛;
- 14: 返回 $\hat{A}$ 。




图 2.8 HNNCL 模型结构图

本研究的主要任务是在药物和疾病多网络数据的基础上,建立了基于邻域对比学习异构图神经网络,预测药物和疾病的关联关系。具体来说,针对药物-药物相似性网络、疾病-疾病相似性网络、药物-疾病关联关系网络,本研究设计了单邻域特征提取模块和多邻域特征提取模块。在编码器中,首先将 SNFEM 用于提取药物-药物(疾病-疾病)相似性网络中的特征信息, MNFEM 用于提取药物和疾病之间关联关系的特征信息,以捕获药物和疾病在不同潜在空间中的重要特征。然后利用对比学习将单邻域特征和多邻域特征进行融合,提升不同邻域空间的信息交互,获得药物和疾病的通用领域特征;同时使用三元损失,对特征信息进行更加细致的区分,降低模型对先验知识的依赖性。最后采用注意力机制将多来源信息进行融合。在解码器中,我们假设药物 H_{drug} 和疾病 H_{dis} 之间的关联得分越高,则 H_{drug} 和 H_{dis} 相关的可能性越大,采用全连接神经网络进行关联关系的预测,并采用预测损失与三元损失相结合方式进行模型的优化。

(1) HNNCL 编码器结构

在编码器中,药物和疾病被初始化为如下所示:

$$H^0 = \begin{bmatrix} H_{drug}^0 \\ H_{dis}^0 \end{bmatrix} = \begin{bmatrix} S_{drug} & 0 \\ 0 & S_{dis} \end{bmatrix} \quad (14)$$

其中 $H^0 \in R^{(N+M) \times (N+M)}$ 。

单邻域特征提取模块结构如图 2.9 所示。在 SNFEM 中,使用 GCN 提取药物(或疾病)的特征信息, GCN 定义如下:

$$GCN(A, H, W) = \sigma(D^{-\frac{1}{2}} A D^{-\frac{1}{2}} H W) \quad (15)$$

其中, A 为邻接矩阵, W 表示权重矩阵, $D = \text{diag}(\sum_j A_{ij})$, $\sigma(\bullet)$ 是 ReLU 函数。




图 2.9 SNFEM 结构图

在 SNFEM 中药物和疾病的嵌入表示为：

$$\hat{H}_s^{l+1} = \begin{bmatrix} \hat{H}_{s_drug}^{l+1} \\ \hat{H}_{s_dis}^{l+1} \end{bmatrix} = \begin{bmatrix} GCN(A^{drug}, H_{drug}^l, W_{drug}^l) \\ GCN(A^{dis}, H_{dis}^l, W_{dis}^l) \end{bmatrix} \quad (16)$$

其中， $\hat{H}_s^{l+1} \in R^{N \times M}$ 是第 l 层的单邻域特征，由第 l 层药物的单邻域特征 $\hat{H}_{s_drug}^{l+1} \in R^{N \times k}$ 和第 l 层疾病的单邻域特征 $\hat{H}_{s_dis}^{l+1} \in R^{M \times k}$ 构成。 A^{drug} 和 A^{dis} 分别表示药物和疾病的邻接矩阵， W^l 表示第 l 层的权重矩阵。

在节点的邻域中，不同的邻居节点对中心节点在结构上具有不同的重要性，在其他方面，也具有不同的重要性，并且受多头注意力的影响，本研究提出了基于多空间邻域注意力机制的多邻域特征提取模块，结构如图 2.10 所示。该机制在多个空间中利用注意力机制学习具有重要意义的邻居特征，从而获得更加全面的节点特征。

在药物-疾病关联网络中，MNFEM 定义了疾病 dis_i 对药物 $drug$ 的重要性，如下所示：

$$\alpha_{dis \rightarrow drug}^l = \frac{\exp(\langle \sigma(W_{drug}^l drug + b_{drug}^l), \sigma(W_{dis}^l dis_i + b_{dis}^l) \rangle)}{\sum_{dis_j \in N^h(dis)} \exp(\langle \sigma(W_{drug}^l drug + b_{drug}^l), \sigma(W_{dis}^l dis_j + b_{dis}^l) \rangle)} \quad (17)$$

其中， $\sigma(\bullet)$ 为非线性激活函数， W 表示权重矩阵， $N^h(dis)$ 表示药物-疾病关联网络中药物 $drug$ 的 h -hop 疾病邻域。




图 2.10 MNFEM 结构图

同理可得到药物 $drug_j$ 对疾病 dis 的重要性：

$$\alpha_{drug \rightarrow dis}^l = \frac{\exp(\langle \sigma(W_{dis}^l dis + b_{dis}^l), \sigma(W_{drug}^l drug_j + b_{drug}^l) \rangle)}{\sum_{drug_i \in N^h(drug)} \exp(\langle \sigma(W_{dis}^l dis + b_{dis}^l), \sigma(W_{drug}^l drug_i + b_{drug}^l) \rangle)} \quad (18)$$

相关研究表明，向量相乘有助于增强向量的共性、降低向量之间的差异。在 MNFEM 中，

使用了基于向量线性聚合的 GCN 进行特征的提取。对于药物 $drug_i$ 其多邻域特征提取模型定义为：

$$\hat{H}_{m_drug_i}^{l+1} = \sigma(\alpha_{dis \rightarrow drug}^l \frac{\sum_j H_{dis_j}^l W^l A_{ij}}{\sum_j A_{ij}} + (1 - \alpha_{dis \rightarrow drug}^l) \frac{\sum_j (H_{dis_j}^l W^l \odot H_{drug_i}^l W^l) A_{ij}}{\sum_j A_{ij}}) \quad (19)$$

其中， $\odot$ 为向量的乘积操作， $\hat{H}_{m_drug_i}^{l+1} \in R^k$ 是药物 $drug_i$ 在第 l 层输出的多邻域特征， W^l 是多邻域特提取模块中第 l 层的权重矩阵。同理，可以得到疾病 dis_j 在第 l 层输出的多邻域特征：

$$\hat{H}_{m_dis_i}^{l+1} = \sigma(\alpha_{drug \rightarrow dis}^l \frac{\sum_i H_{drug_i}^l W^l A_{ij}}{\sum_i A_{ij}} + (1 - \alpha_{drug \rightarrow dis}^l) \frac{\sum_i (H_{drug_i}^l W^l \odot H_{dis_j}^l W^l) A_{ij}}{\sum_i A_{ij}}) \quad (20)$$

为了增强单邻域特征提取模块与多邻域特征提取模块的关联性，更好的捕获药物和疾病的通用特征，HNNCL 使用对比学习并行融合单邻域特征和多邻域特征。融合之后第 l 层的药物特征为：

$$\hat{H}_{drug}^{l+1} = Contrastive(\hat{H}_{s_drug}^{l+1}, H_{m_drug}^{l+1}) \quad (21)$$

同理可得到第 l 层的疾病特征：

$$\hat{H}_{dis}^{l+1} = Contrastive(\hat{H}_{s_dis}^{l+1}, H_{m_dis}^{l+1}) \quad (22)$$

为了避免梯度消失问题，HNNCL 在融合的特征之后增加了一个 residual skip connection，得到药物和疾病的嵌入表示：

$$H^{l+1} = \hat{H}^{l+1} + H^l = \begin{bmatrix} \hat{H}_{drug}^{l+1} + H_{drug}^l \\ \hat{H}_{dis}^{l+1} + H_{dis}^l \end{bmatrix} \quad (23)$$

H^{l+1} 是药物和疾病在第 l 层的输出。最后引入注意力层，将不同卷积层的嵌入表示与注意力机制相结合，进一步提升预测性能。药物和疾病的最终嵌入表示如下：

$$\begin{bmatrix} H_{drug} \\ H_{dis} \end{bmatrix} = \sum_{l=1} \beta^l H^l \quad (24)$$

其中 $\beta^l \in R$ 由神经网络自动进行学习并初始化为 $\frac{1}{L}$ ，表示不同卷积层的嵌入对最终嵌入的贡献。 $H_{drug} \in R^{N \times k}$ 是药物实体的最终嵌入表示， $H_{dis} \in R^{M \times k}$ 是疾病实体的最终嵌入表示。

(2) HNNCL 解码器结构

为了重建药物和疾病之间的联系，HNNCL 的解码器的公式如下：

$$\hat{A} = f(H_{drug}, H_{dis}) = sigmoid(H_{drug} H_{dis}^T) \quad (25)$$

其中 $\hat{A} \in R^{N \times M}$ 是预测概率得分矩阵，药物和疾病之间关联关系的预测分数由相应的 $\hat{A}_{ij}$ 给出。

(3) HNNCL 模型优化

为了更好地进行药物-疾病关联关系的预测，HNNCL 通过最小化加权二元交叉熵损失和三元损失的总和来学习参数，如下所示：

$$LOSS = - \left(\frac{1}{N \times M} \left(\gamma \times \sum_{(i,j) \in A^+} \log \hat{A}_{ij} + \sum_{(i,j) \in A^-} (1 - \log A_{ij}) \right) + \max \left(\|H - H^P\|_2 - \|H - H^N\|_2 + \alpha, 0 \right) \right) \quad (26)$$

其中 (i, j) 表示药物 $drug_i$ 和疾病 dis_j 对, A^+ 表示所有已知药物-疾病关联对的集合, A^- 表示所有未知的药物-疾病关联对的集合。 H 为当前节点的输出, H^P 和 H^N 分别为对比学习中正集合和负集合中节点的平均输出向量。

三、方案实现

3.1 基于图信息融合的 Transformer 用于药物-靶点相互作用预测

3.1.1 实验数据

实验中使用的数据包括药物和靶点相互作用数据、靶点的序列数据和药物的 SMILES 序列数据。从 DrugBank 数据库中提取了具有相互作用关系的药物和靶点数据，分别从 KEGG 数据库和 PubChem 数据库中提取了靶点的序列数据和药物的 SMILES 序列数据。在去除缺少序列表示的 DTI 数据后，共得到了 12496 个药物分子结构、5462 个靶点序列和 21158 个 DTI 数据，如表 3.1 所示。本研究将已知的 DTI 数据作为正例、目前未知的 DTI 数据作为负例，同时按照正例：负例=1：2 的比例随机构造了负例，并加入到数据中。最后按照训练集：测试集=8：2 的比例划分了数据集。

表 3.1 数据集详细信息表

节点类型	数量	DTI 类型	数量
药物	12496	正例（已知）	21158
靶点	5462	负例（未知）	42316
总计	17958	总计	63474

3.1.2 实验设置

本研究使用了来自 PubChem 数据库中与 Delta 变体有关的 COVID-19 DTI 数据进行案例研究。Deep MGT 使用 RAM 为 24GB 的 NVIDIA GeForce RTX 3090 显卡进行训练，使用具有优化后损失函数的 Adam 优化器进行权重更新。模型实验参数如表 3.2 所示。

表 3.2 模型实验参数

实验参数	大小
Epoch	150
Batch	32
学习率	0.0001
衰减率	0.0001
Dropout	0.1
CNN filters	128
CNN 卷积核	10,15,20
CNN 步长	1
GCN 输入	75
GCN 隐藏层数量	2
Transformer 多头注意力机制的数量	2

3.1.3 评价指标

为了全面的评价模型的有效性，本研究选择了四个指标来评估提出的模型：假正率 (FPR)-真正率 (TPR) 曲线下的面积 (AUC)、召回率 (Recall)-精确率 (Precision) 曲线下的面积 (AUPR)、F1 和准确率 (ACC)，同时本研究还使用 Sensitivity (Sen)、Specificity (Spe)、Precision (Pre) 指标来更全面的评价模型的性能。FPR、TPR、Recall、F1、ACC、Sen、Spe 和 Pre 的定义如下：

$$FPR = \frac{FP}{TN + FP} \quad (27)$$

$$TPR = Recall = \frac{TP}{TP + FN} \quad (28)$$

$$F1 = \frac{2TP}{2TP + FP + FN} \quad (29)$$

$$ACC = \frac{TP + TN}{FP + FN + TP + TN} \quad (30)$$

$$Sen = \frac{TP}{P} \quad (31)$$

$$Spe = \frac{TN}{N} \quad (32)$$

$$Pre = \frac{TP}{TP + FP} \quad (33)$$

其中 TP 表示被正确识别的具有相互作用关系的药物-靶点的数量, TN 分别表示被正确识别的没有相互作用关系的药物-靶点的数量, FP 表示具有相互作用关系的药物-靶点数据但在实验中没有被正确识别的数量, FN 表示不具有相互作用关系的药物-靶点数据且在实验中没有被正确识别的数量。 P 表示具有相互作用关系的药物-靶点数据的数量, N 表示没有相互作用关系的药物-靶点数据的数量。

3.1.4 Deep MGT 在对比试验中的性能

为了验证 Deep MGT 模型的性能, 本研究将所提出的模型 Deep MGT 与两种机器学习模型: 随机森林和 SVM, 以及五种 SOTA 深度学习模型进行了比较。

在对比实验中, 五种深度学习模型总结如下:

- Deep DTA: 使用 CNN 对蛋白质序列和化合物 1D 表示进行建模, 预测蛋白质和化合物的亲和力。
- Deep DTI: 基于无监督预训练模型提取描述符的表示, 并使用分类模型进行 DTI 预测。
- Deep Conv-DTI: 专注于靶点序列残基信息的提取, 以进行 DTI 的预测。
- TransformerCPI: 仅使用蛋白质序列进行化合物-蛋白质相互作用预测。
- ML-DTI: 使用基于注意的互学习机制拟合药物编码器和靶点编码器, 进行 DTI 的预测。

表 3.3 Deep MGT 与基准模型的 DTI 预测性能的比较

模型	AUC	AUPR	F1	ACC
随机森林	58.62%	49.68%	60.06%	66.83%
SVM	60.62%	53.36%	62.82%	67.93%
Deep DTA	75.96%	63.71%	71.95%	79.81%
Deep DTI	79.39%	70.04%	72.86%	80.33%
Deep Conv-DTI	86.10%	68.35%	72.36%	80.68%
TransformerCPI	86.69%	74.39%	75.66%	83.26%
ML-DTI	88.02%	77.63%	77.10%	83.34%
Deep MGT (我们的方法)	90.24%	77.11%	79.31%	85.15%

本研究将这些对比方法应用于研究中的数据集中, 并对模型的一些参数进行了修改。所得实验结果如表 3.3 所示。实验结果表明, ML-DTI 模型和我们的方法在各个评价指标上的性能均优于 Deep DTA、Deep DTI、Deep Conv-DTI 和 TransformerCPI 模型。这是因为 Deep

DTA、Deep DTI、Deep Conv-DTI 和 TransformerCPI 模型专注于靶点的序列结构，在一定程度上忽略了对药物分子特征的捕获。然而，ML-DTI 模型和我们的方法在捕获靶点的序列特征的同时，更专注于挖掘药物分子信息，从而在数据中获取了更多的特征信息，并提高了模型的性能。基于机器学习的方法在整体性能上与其他基于深度学习方法具有较大的差距，随机森林模型是所有模型中性能最差的。这从侧面也体现出了深度学习对复杂数据具有更强的特征提取能力。

通过比较 Deep DTA、Deep DTI、Deep Conv-DTI 模型的实验结果可以看出，Deep Conv-DTI 模型取得了最好的实验结果。这是因为 Deep DTI 使用整个靶点序列中的物理化学性质进行特征，整个蛋白质序列中包含了很多不参与化合物相互作用的子序列或结构域，导致模型捕获的靶点关键特征较少，降低了模型的性能。Deep DTA 是针对特定蛋白质而进行设计和优化的，对于有多种类别蛋白质的靶点数据，其性能并不佳。相反，Deep Conv-DTI 模型通过提取靶点序列中残基的关键信息，有效的提取了靶点序列的特征，取得了较好的模型效果。

通过比较 ML-DTI 模型和本研究提出的方法的实验结果，可以清楚的看出，本研究提出的方法在 AUC、F1 和 ACC 评价指标的结果均优于 ML-DTI 模型，分别比 ML-DTI 高 2.22%、2.21%和 1.81%。这是因为本研究提出的方法利用 Transformer 网络对图卷积神经网络隐藏层中的信息进行了进一步的处理，更加有效的提取了药物分子中的结构信息。而 ML-DTI 在多头注意力机制和位置感知注意力机制的基础上，在编码器中利用相互学习机制来拟合药物和靶点的之间的距离。但是不可忽视的是，ML-DTI 利用全局概率图进行特征的过滤和筛选，可以从全局的角度进行药物和靶点特征信息的学习。因此，ML-DTI 在 DTI 预测实验中获得了最高的平均 AUPR(AUPR=77.63%)，比我们的方法高 0.5%。

3.1.5 消融实验

为了验证 Deep MGT 中各个模块的有效性，我们设计并进行了消融实验，结果如表 3.4 所示。

表 3.4 Deep MGT 在 DTI 预测消融实验中的结果

评价指标	w/o MCGCN and Transformer	w/o Transformer	w/o Multi-Head Self-attention	Deep MGT (我们的方法)
AUC	86.10%	87.36%	88.53%	90.24%
AUPR	68.35%	70.69%	72.97%	77.11%
F1	72.36%	74.78%	77.26%	79.31%
ACC	80.68%	80.89%	82.96%	82.17%
Sen	76.35%	78.66%	81.50%	80.68%
Spe	81.62%	83.08%	84.90%	86.73%
Pre	70.26%	74.34%	74.88%	76.65%

注：“w/o”代表“没有”。

在消融实验中，模型变量总结如下：

- **w/o MCGCN and Transformer**：药物特征提取使用全连接神经网络，靶点特征提取使用卷积神经网络，直接将全连接神经网络和卷积神经网络的输出作为药物和靶点的最终嵌入表示。
- **w/o Transformer**：药物特征提取仅使用分子补全图神经网络，靶点特征提取使用卷积神经网络，将分子补全图卷积神经网络的输出和卷积神经网络的输出作为药物和靶点的最终嵌入表示。
- **w/o Multi-Head Self-attention**：药物特征提取使用分子补全图神经网络和 Transformer 网络，将分子补全图神经网络输出作为 Transformer 网络的输入，靶点

特征提取使用卷积神经网络，将 Transformer 网络的输出和卷积神经网络的输出作为药物和靶点的最终嵌入表示。

- **Deep MGT**: 药物特征提取使用分子补全图神经网络和改进的 Transformer 网络，将分子补全图神经网络每一层的输出作为 Transformer 网络中不同多头注意力模块的输入，并将不同的多头注意力模块的输出聚合作为药物的最终嵌入表示。靶点特征提取使用卷积神经网络。

MCGCN 的有效性。如表 3.4 所示，MCGCN 可以进一步提高 AUC、AUPR、F1 和 ACC 的性能，四项性能指标分别提高了 1.2%、2.3%、2.4%、0.2%。基于 MCGCN，Deep MGT 对药物分子结构图中的原子信息和原子间的相互作用信息进行了充分的学习，有效地保留了药物分子的特征信息。这就是为什么 MCGCN 可以提高 DTI 的预测性能的原因。

Transformer 网络的有效性。如表 3.4 所示，Transformer 网络在 AUC、AUPR、F1 和 ACC 上的性能分别提高了 1.2%、2.3%、2.5%、2.1%。实验结果表明，Transformer 网络从 MCGCN 中提取了相关特征信息，有效的对图卷积网络中隐藏层的信息进行了提取，提高了 Deep MGT 的预测性能。

多头自我注意力模块的有效性。多头自注意力模块在 AUC、AUPR、F1 和 ACC 等上有了实质性的改进，分别提高了 1.7%、4.2%、2.0%、2.2%，尤其在 AUPR 上的性能提升最为显著。这与我们的预期一致，即多头自注意力模块不仅最大程度地保留了 MCGCN 的特征信息，而且还提取了 MCGCN 隐藏层中缺失的信息。它有效地克服了图神经网络对边缘特征学习的不足，提高了模型的预测性能。

3.1.6 Deep MGT 在不平衡数据中的性能

在实际研究中，自然界中的大多数药物-靶点相互作用关系是未知，为了使本研究提出的模型更贴近实际的药物重定位应用，本研究进行了 Deep MGT 模型在类别不平衡数据集上的稳健性测试实验。在保持训练数据类别平衡性不变的情况下，我们从未知的药物-靶点相互作用关系中随机抽取部分数据并将测试数据按照正样本：负样本=1: 2、1: 5、1: 10 和 1: 20 的比例进行了不同程度的扩充，以构造不同比例的类别不平衡数据。实验结果如表 3.5 所示。实验结果表明，Deep MGT 在不同比例的类别不平衡数据上的综合性能波动较小，并且 AUC 和 ACC 的性能有随着样本比例的扩大而呈上升的趋势。因此，本研究提出的方法受类别不平衡的影响较小，具有一定的应用前景。

表 3.5 Deep MGT 在不平衡数据集上的 DTI 预测性能

比例 (正例：负例)	AUC	ACC	Sen	Spe
1: 2	90.24%	85.15%	82.17%	86.73%
1: 5	91.88%	87.79%	80.35%	89.32%
1: 10	92.82%	88.43%	83.98%	88.88%
1: 20	92.95%	88.98%	83.53%	89.29%

3.1.7 案例探究：Deep MGT 用于 COVID-19 的药物重定位研究

为了验证本研究模型用于药物重定位研究的有效性，本研究将 Deep MGT 模型用于寻找 COVID-19 的治疗药物。众所周知，COVID-19 的 Delta 变体目前已经覆盖 130 个国家和地区，包括美国在内的多个国家 Delta 变体确诊病例数已经超过 Alpha 变体确诊病例。Delta 变体比之前的 COVID-19 的传染性高 55%到 90%、比 Alpha 变体的传染性高 30%到 100%。Bernal 等人的研究表明，Delta 为 COVID-19 的主要治病靶点。由此可见，快速发掘和发现有效抑制 Delta 变体的药物对全球新冠疫情的防控具有重要意义。因此本研究从 PubChem 数据库中提取了有关 Delta 靶点相关信息，并利用 Deep MGT 模型进行潜在治疗药物的预测，实验结果如表 3.6 所示。

表 3.6 Deep MGT 推荐的与 COVID-19 相关的前五种药物

序号	药物编号	药物名称	依据
1	CID:33741	Tramadol	Tramadol could protect COVID-19 patient from disease complications by increases the antioxidant enzymes superoxide dismutase and glutathione peroxidase while diminished malondialdehyde.
2	CID:5311356	Pholcodine	None
3	CID:5743	Dexamethasone	Recent clinical trial has revealed that dexamethasone and convalescent plasma treatment can reduce mortality in patients with severe forms of COVID-19.
4	CID:2160	Amitriptyline	Treating volunteers with a low dose of amitriptyline prevents infection of freshly isolated nasal epithelial cells with pp-VSV-SARS-CoV-2 spike.
5	CID:5360696	Dextromethorphan	In this scenario, we undertook a repurposing project of common cough and cold drugs – Dextromethorphan, Prednisolone and Dexamethasone to explore their anti-Covid property. Individual and sequential docking study with MD simulation, RMSD and RMSF analysis revealed a combination of these three considered ligands may prove to be a successful therapy against COVID-19.

在实验结果中，排名前五的药物中有包含 Tramadol 在内的四种药物已经用于 COVID-19 的临床治疗或有文献支持对 COVID-19 有抑制作用，Tramadol、Amitriptyline 和 Dextromethorphan 均与 Delta 靶点具有密切的相互作用关系。其中，Dexamethasone 和 Dextromethorphan 是被广泛应用于 COVID-19 的临床治疗并成功的缓解了 COVID-19 的并发症。Tramadol 可以通过增加抗氧化酶、超氧化物歧化酶和谷胱甘肽过氧化物酶，同时减少丙二醛的影响，从而保护 COVID-19 患者免受疾病并发症的影响。有研究表明，用不同浓度的 Amitriptyline 处理细胞后，细胞被感染的几率降低了 90%，这同样为 Amitriptyline 用于 COVID-19 治疗提供了基础。

为了证明 Deep MGT 的特征提取的有效性，本研究使用 Deep Conv-DTI 方法进行了 COVID-19 潜在治疗药物的预测实验，并与本研究提出的模型进行了比较。结果显示，Deep Conv-DTI 预测的前 5 种药物中仅包含两种 COVID-19 的治疗药物，少于我们的方法中的四种药物。这是因为 Deep MGT 将 SMILES 序列表示为一个图，利用 MCGCN 和 Transformer 网络有效地提取了药物分子中原子间的相互作用信息。

除 COVID-19 外，本研究还利用 Deep MGT 预测了阿尔茨海默病的潜在治疗药物。在本实验中，选择与阿尔茨海默病密切相关的 Apolipoprotein E 为靶点，并在 KEGG 数据库和 PubChem 数据库中寻找相应的作用药物，构建 DTI 数据。选择适当的阴性样本进行样本扩展。在预测的前 5 种药物中，Rivastigmine Tartrate 和 Memantine Hydrochloride 已经被用于阿尔茨海默病的临床治疗。

3.2 基于邻域对比学习异构图神经网络药物重定位模型

3.2.1 实验设置

在实验中，本研究在四个数据集中使用 10 折交叉验证。在交叉验证中，本研究从数据集中随机选取 10% 的已知关联数据和 10% 的未知关联数据作为测试集，其余数据作为训练集。在模型训练中，实验参数如表 3.8 所示，训练最大 Epoch 为 600，GCN 隐藏层为 3，Dropout 大小为 0.1，多邻域节点聚合数量为 6，同时采用 Adam 优化器进行模型优化。为了评估 HNNCL 的整体性能，本研究在四个数据集上使用假 FPR-TPR 曲线下的面积 (AUROC)、Recall-Precision 曲线下的面积 (AUPR) 评价指标。

表 3.7 模型实验参数

实验参数	大小
Epoch	600
学习率	0.05
Dropout	0.1
多邻域节点聚合数	6
GCN 隐藏层数量	3

3.2.2 HNNCL 在交叉验证中的性能

为了评估本研究提出模型 HNNCL 的性能，将 HNNCL 与下面 7 种最先进的药物重新定位方法进行了比较，包括 NRLMF、DRRS、SCMFDD、DRIMC、LAGCN、NIMCGCN 和 DRHGCN。

- NRLMF：专注于通过逻辑矩阵分解对药物-靶标相互作用的概率进行建模。
- DRRS：使用低阶矩阵近似和随机算法，通过推荐已知药物-疾病关联的新治疗方法进行药物重定位研究。
- SCMFDD：基于特征相似性约束和特征矩阵分解的方法进行药物-疾病关联关系预测。
- DRIMC：是一种基于改进贝叶斯模型，利用诱导矩阵分解的方式进行药物重定位的方法。
- LAGCN：基于分层注意力图卷积网络进行药物疾病关联预测。
- NIMCGCN：在图卷积网络和诱导矩阵的基础上预测 miRNA 与疾病的关联。后来，它被证明在药物重新定位方面具有巨大潜力。
- DRHGCN：是一种基于 GCN 的异构信息融合深度学习方法，以精确发现疾病的候选药物。

本研究在四个数据集上进行了相应的实验，实验结果如表 3.8 所示，粗体数值表示最佳性能。在实验中，DRRS、SCMFDD、LAGCN、DRIMC、NIMCGCN 和 DRHGCN 均采用出版时提供的最佳超参数。对于 NRLMF，本研究设置子空间 $R=200$ ，正则化参数 $\lambda_d = \lambda_t = 0.125$ ， $\alpha = 0.25$ ， $\beta = 0.125$ ，学习率为 0.5。

由表 3.8 可知，本研究 HNNCL 模型取得了最佳的平均 AUPR 和平均 AUROC(平均 AUPR 为 57.4%，平均 AUROC 为 93.8%)，分别高于排名第二的 DRHGCN 模型 3.5% 和 0.4%。与 DRHGCN 相比，HNNCL 更加注重邻域信息之间的交互，更好的捕获了多个潜在空间中的重要性特征，在多空间中聚集了更适用药物-疾病相互作用预测任务的通用特征。应当注意，HNNCL 在两个数据集 (Gottlieb 的数据集和 Luo 的数据集) 上取得了最好的 AUPR，在三个数据集 (Gottlieb 的数据集、Liang 的数据集和 Yu 的数据集) 上取得了最好的 AUROC，仅在 Luo 的数据集上比 DRHGCN 低 0.1%。这进一步说明本研究提出的方法在多邻域特征提取和多空间信息融合方面具有较强的能力，表现出了令人满意的综合性能。但是，在一些

个别数据集上也出现了性能上的差距，这可能是与对比学习中负样例的生成策略有关，影响了模型的整体性能。

表 3.8 HNNCL 与基准模型 10 折交叉验证的性能对比

模型	Gottlieb 的数据集		Luo 的数据集		Liang 的数据集		Yu 的数据集		平均性能	
	AU	AU	AU	AU	AU	AU	AU	AU	AU	AU
	PR	ROC	PR	ROC	PR	ROC	PR	ROC	PR	ROC
NRLMF	52.2	93.6	61.6	94.9	35.9	77.6	46.2	92.3	49.0	89.6
DRRS	47.5	92.8	57.2	94.8	39.7	84.1	34.2	92.7	44.7	91.1
SCMFDD	5.1	77.6	5.2	79.3	49.5	85.0	3.6	76.9	15.9	79.7
DRIMC	31.4	91.3	39.2	93.3	30.6	75.7	26.7	93.2	32.0	88.4
LAGCN	13.0	88.4	19.1	92.0	50.1	81.2	11.4	93.5	23.4	88.8
NIMCGCN	34.4	83.2	44.1	85.5	44.0	82.6	27.4	83.3	37.4	83.7
DRHGCN	54.3	94.4	64.0	96.0	55.5	87.6	41.7	95.7	53.9	93.4
HNNCL (我们的方法)	62.3	95.4	67.5	95.9	55.2	87.8	44.6	96.1	57.4	93.8

注：评价指标单位为%。

在 Gottlieb 的数据集上，与其他七种方法相比，HNNCL 表现出了最优的 AUPR(62.3%) 和 AUROC(95.4%)，远高于其他方法。其中，AUPR 分别比 DRHGCN 高 8%、比 NRLMF 高 10.1%、比 DRRS 高 14.8%、比 NIMCGCN 高 27.9%，AUROC 分别比 DRIMC 高 4.1%、比 LAGCN 高 7%、比 NIMCGCN 高 12.2%、比 SCMFDD 高 17.8%。这在一定程度上说明，本研究所提出的 SNFEM 和 MNFEM 模块可以更好的获取多空间中药物和疾病的重要性特征，对比学习有效聚合了药物和靶点的邻域特征，提高了模型的预测性能。在 Luo 的数据集和 Liang 的数据集上，HNNCL 与 DRHGCN 平分秋色。在 Yu 的数据集上，HNNCL 的 AUPR 比 NRLMF 低 1.6%。综合 HNNCL 在各个数据集上的表现，可以看出，HNNCL 更适用于稀疏性较小的数据，而对于稀疏性较大的数据（例如 Yu 的数据集，稀疏性为 0.0059）其综合性能并不突出。

表 3.8 中的结果清楚的展示了基于异构网络的方法（DRHGCN 和 HNNCL）在性能方面优于其他方法。这是因为通过区分不同类型和不同来源的数据，既能保证网络拓扑结构被充分利用，又可以最大程度的减少网络中特定信息的丢失，更加全面的捕获药物和疾病的信息。LAGCN 将药物领域和疾病领域的拓扑信息不加区别的混合，导致其平均 AUPR 和平均 AUROC 分别比 HNNCL 低 34%和 5%。这也进一步验证了不同邻域的网络中存在大量的网络信息。DRRS 和基于诱导矩阵的方法（DRIMC 和 NIMCGCN）没有充分利用药物的多种相似性，导致其性能相对较差。SCMFDD 是所有方法中综合性能最差的。SCMFDD 仅使用约束矩阵和矩阵分解的方式进行药物-疾病关联关系预测，对药物和疾病的特征信息提取不充分，从而导致预测性能不佳。不可忽视的是，在 Yu 的数据集上，NRLMF 取得了最佳的 AUPR(46.2%)，比 HNNCL 高 1.6%。原因是 Yu 的数据集中包含了较多的药物和疾病种类，且药物和疾病之间的关联性较低。NRLMF 的输入仅包含药物-药物相似性和疾病-疾病相似性，而 HNNCL 的输入包含已知的药物-疾病相关性，稀疏的关联性在一定程度上限制了 HNNCL 的性能。

3.2.3 消融实验

本研究所提出的 HNNCL 主要由三部分组成：邻域特征（Neighborhood feature, NF）提取模块、对比学习（Contrastive Learning, CL）模块和三元损失(Triplet Loss, TL)模块。为了分析每个模块的贡献，本研究在四个数据集上进行了消融实验并对 HNNCL 的每部分进行了

比较。

在消融实验中，模型变量总结如下：

- **w/o NF & CL & TL**：主要由基于 GCN 的编码器和解码器组成。具体来讲，编码器仅利用双线性聚合器和 GCN 来提取药物和疾病的特征，解码器基于药物和疾病的嵌入对预测关联概率得分。
- **w/o CL & TL**：主要由基于邻域特征提取的编码器和解码器组成。在 w/o NF & CL & TL 的基础上，编码器采用单邻域特征提取模块和多邻域特征提取模块进行特征提取，解码器基于药物和疾病的嵌入对预测关联概率得分。
- **w/o TL**：主要由基于邻域特征提取和对比学习的编码器和解码器组成。在编码器中采用对比学习并行融合单邻域特征和多邻域特征，解码器基于药物和疾病的嵌入对预测关联概率得分。
- **HNNCL**：主要由基于邻域特征提取和优化的对比学习的编码器和解码器组成。在 w/o TL 的基础上，利用三元损失对邻域特征融合模块进行优化，解码器基于药物和疾病的嵌入对预测关联概率得分，并使用预测损失函数和三元损失共同优化模型。

图 3.1 显示了 HNNCL 及各种变体在四个基准数据集上的 AUPR。

邻域特征提取模块的有用性。如图 3.1 所示，邻域特征提取模块在 Gottlieb 的数据集、Luo 的数据集、Liang 的数据集和 Yu 的数据集上的 AUPR 性能分别提升了 0.4%、2.6%、7.1% 和 2.5%。这说明，邻域特征提取模块可以对不同空间域的网络进行了有效的区分，并学习到不同空间域网络中的特定信息，在药物空间和疾病空间等潜在空间中有效的捕获了药物和疾病的重要性特征，进一步提升了模型对 DDI 的预测性能。




图 3.1 HNNCL 及各种变体在四个基准数据集上的 AUPR

对比学习的有用性。在图 3.1 中，使用对比学习后的模型性能虽然有一定的提升，但是性能整体幅度不大。实验结果表明，融合单邻域特征和多邻域特征有助于提升不同邻域空间的信息交互，可以在一定程度上提取药物和疾病的通用特征和提升模型的预测性能。但是这种信息交互对模型的性能提升有一定的限度，这可能与对比学习中负样例的生成策略有一定的关系。

三元损失的有用性。未使用三元损失的模型的 AUPR 与我们最终的模型相比，在四个基准数据集上分别下降了 0.8%、2.9%、0.2% 和 1.8%。显然，三元损失能改进模型的预测性能。最可能的原因是，三元损失可以对差异较小的样例进行更好的嵌入表示，学习到更细微

的特征信息，从而可以在一定程度上弥补对比学习中负样例特征提取不足的缺点，在对比学习的基础上进一步对药物和疾病的邻域特征进行了整合，提高了邻域特征的通用性，降低模型对先验知识的要求，提升模型的预测性能。

3.2.4 多邻域聚合节点数量对 HNNCL 性能的影响

在 MNFEM 模块中，邻域空间中节点对中心节点具有不可忽视的影响。为探究邻域空间中聚合节点的数量对 HNNCL 性能的影响，我们将聚合节点的数量设置为不同的数值，进行 DDI 的预测，实验结果如图 3.2 所示。




图 3.2 不同聚合节点数下 HNNCL 在四个基准数据集上的性能

为了探究不同聚合节点数目对 HNNCL 性能的影响，我们将聚合节点数目分别设置为 2、4、5、6、8、10 和 15，并在四个数据集上进行了相关实验。如图 3.2 所示，在聚合节点数目为 6 是，HNNCL 在四个数据集上均取得了最好的性能。当聚合节点数目小于 6 时，模型的性能随着聚合节点数目的增加而提高；相反，当聚合节点数目大于 6 时，模型的性能随着聚合节点数目的增加而降低。实验结果证实了邻域空间内存在大量的特征信息，多邻域聚合有助于捕获药物和疾病的重要性信息；但盲目的增加聚合节点，会导致药物或疾病实体本身的特征信息被掩盖，导致对其通用特征学习不足，进而会降低模型整体性能。

3.2.5 案例探究：HNNCL 用于阿尔茨海默症的药物重定位研究

为了进一步验证 HNNCL 在药物重定位实验中的可靠性，本研究利用 HNNCL 对阿尔茨海默症进行候选药物预测研究。在阿尔茨海默症潜在药物预测过程中，本研究使用 Gottlieb 的数据集，并将所有已知的药物-疾病关联关系作为训练集，将未知的药物-疾病关联关系作为候选集。HNNCL 对所有候选药物-疾病关联进行相互作用的概率预测，并根据预测概率对候选药物进行排序。

在阿尔茨海默症的药物重定位研究中，本研究选取了预测排名前 5 的治疗药物，如表 3.9 所示。在这 5 种药物中，有 4 种药物被证实对阿尔茨海默症具有治疗或缓解作用。Levodopa 是所有预测药物中排名第一的可用于治疗阿尔茨海默症的药物，并在 PubChem 和 CTD 等数据库得到了证实。先前的相关文献证实，Amantadine 可以提高阿尔茨海默症患者的细胞活性。在之前的研究指出 Memantine hydrochloride 是阿尔茨海默症、帕金森病等疾病的有效治疗选择。Rivastigmine tartrate 也在相关文献中被证实可以有效缓解阿尔茨海默症的症状。

为了证明 HNNCL 的提取特征的有效性，本研究使用 LAGCN 方法进行了阿尔茨海默症潜在治疗药物的预测实验，并与本研究提出的模型进行了比较。结果显示，LAGCN 预测的前 5 种药物中仅包含三种阿尔茨海默症的治疗药物，少于我们的方法中的四种药物。这是因为 HNNCL 对邻域信息进行了有效融合，捕获了潜在空间中药物和疾病的关键性特征，并进

行了有效聚合，更好的保留了药物和疾病的通用信息。

表 3.9 HNNCL 推荐的与阿尔茨海默症相关的前五种药物

序号	药物编号	药物名称	依据
1	DB01235	Levodopa	Thus cognitive deficits and stereotypies may be due to changes in the dopaminergic system as they could be ameliorated by levodopa treatment, that might also have a therapeutic significance for AD.
2	DB00989	Rivastigmine tartrate	We describe here a population pharmacokinetic analysis of the possible effects of renal impairment on steady-state plasma concentrations of rivastigmine and its metabolite NAP226-90 after rivastigmine patch (5 cm ² [4.6 mg/24 h], 10 cm ² [9.5 mg/24 h], 15 cm ² [13.3 mg/24 h], and 20 cm ² [17.4 mg/24 h]) and capsule (1.5, 3, 4.5, and 6 mg/12 h) treatment in patients with Alzheimer's disease.
3	DB00245	Benzatropine	NONE
4	DB01043	Memantine hydrochloride	We conclude from our review that memantine may be an effective therapeutic option in managing AD, frontotemporal dementia, dementia with Lewy bodies, Parkinson's disease dementia and vascular dementia. When a diagnosis of the dementia subtype cannot be clearly identified or when there is no clear therapeutic option, memantine may be simple and safe.
5	DB00915	Amantadine	Significant improvement of mental status was noted with amantadine therapy in three patients in whom autopsy subsequently showed Alzheimer's disease. Two patients showed a dramatic improvement during the treatment. Their mute, immobile states were reversed and they were able to speak a few coherent words. Their mental status deteriorated when the drug was withdrawn.

四、运行结果/应用效果

4.1 项目依赖环境

4.1.1 DeepMGT-DTI

(1) 概述

这个 Python 脚本的主要目的是预测药物与靶点的相互作用。该脚本包含部分原始实验数据（详见数据文件夹）和可以在 GPU 模型 NVIDIA 1080Ti 服务器上成功运行的代码。

(2) 环境

```
Python = 3.6.13
Tensorflow-gpu = 1.15.0
keras = 2.3.1
pytorch = 1.7.1
scikit-learn = 0.24.2
rdkit = 2020.09.1.0
```

(3) 运行方法

- 1) 生成药物分子结构的图形表示：运行 `extract_smiles.ipynb`。
 - 2) 模型训练和预测：运行 `model.py`。
- 运行 py 文件的命令：

```
model.py
[--train_dti_dir train_dti_dir]
[--train_compound_dir train_compound_dir]
[--train_protein_dir train_protein_dir]
[--predict -n]
[--test_dti_dir train_dti_dir]
[--test_compound_dir test_compound_dir]
[--test_protein_dir test_protein_dir]
[--window-sizes [window_sizes]]
[--protein-layers [protein_layers]]
[--fc-layers [fc_layers]]
[--learning-rate learning_rate]
[--n-epoch n_epoch]
[--prot-vec prot_vec]
[--prot-len prot_len]
[--output output]
```

4.1.2 HNNCL

(1) 概述

这个 Python 脚本的主要目的是预测药物与疾病的相互作用。该脚本包含部分原始实验数据（详见数据文件夹）和可以在 GPU 模型 NVIDIA 3090Ti 服务器上成功运行的代码。

(2) 环境

```
python == 3.6.12
pytorch == 1.6.0
pytorch-lightning==1.0.8
```

(3) 运行方法

```
demo.py [-h] [--model MODEL]
[--epochs EPOCHS] [--debug]
```

```
[--profiler PROFILER] [--comment COMMENT]
[--dataset_name {Cdataset,Fdataset,lrssl,hvdv,lagcn}]
[--drug_neighbor_num DRUG_NEIGHBOR_NUM]
[--disease_neighbor_num DISEASE_NEIGHBOR_NUM]
[--split_mode {global,local}] [--n_splits N_SPLITS]
[--drug_idx DRUG_IDX] [--disease_idx DISEASE_IDX]
[--global_test_all_zero] [--train_fill_unknown]
[--dataset_type {FullGraphDataset,PairGraphDataset}]
[--seed SEED] [--embedding_dim EMBEDDING_DIM]
[--layer_num LAYER_NUM] [--lr LR] [--dropout DROPOUT]
[--edge_dropout EDGE_DROPOUT]
[--neighbor_num NEIGHBOR_NUM]
[--smooth] [--gnn_mode GNN_MODE]
```

4.2 应用结果

本研究基于以上实验及 vue、flask 框架开发 web 端药物-疾病预测系统



图 4.1 用户登录界面





图 4.2 预测模型管理界面



五、创新与特色

5.1 项目创新

本团队所提出的基于图信息融合的 Transformer 网络用于药物-靶点关系预测的创新性为：(1) 将药物的 SMILES 序列表示为药物分子结构图，更好的展现了药物分子中原子之间的关系，同时克服了 SMILES 序列的脆弱性；(2) 采用分子补全图卷积神经网络学习和捕获药物分子结构图的特征，有效提取了药物化合物分子结构中的原子信息；(3) 采用改进多头注意力机制的 Transformer 网络捕获图卷积神经网络隐藏层中的信息，保留了原子间相互作用的原始信息，克服了图卷积神经网络对边特征学习不足的问题。

本团队所提出的基于邻域对比学习异构图神经网络用于药物-疾病关联关系预测的创新性为：(1) 我们通过节点聚合和邻域融合而不是特征拼接的方式构建邻域特征提取模型，克服了基于启发式特征提取方式线性表示能力弱的缺点，有效提取了药物和疾病在多个潜在空间中的重要信息；(2) 利用对比学习对单域特征和多邻域特征进行平行融合，选择性的聚合了药物和疾病在多个邻域空间中的特征，增强了不同邻域空间的信息交互；(3) 提出预测损失和负样本生成损失相结合的混合优化策略，提高邻域特征的有效性和通用性，减少对先验知识的依赖。

5.2 项目特色

生物医药科技对国民经济和人类社会意义重大，已成为大国竞争的核心科技之一。截止 2021 年，我国生物医药市场规模已达 3.57 万亿元，发展潜力不容小觑。但是，FDA 最新数据表明，新药物平均研发周期为 8.1 年，平均研发成本为 2-30 亿美元。传统药物研发昂贵、费时、成功率低，已无法满足市场的需求。药物重定位，即发掘现有药物新的适应症，正逐渐成为医药生物领域的研究热点。

针对传统药物行业存在的研发周期长、成本高、靶标识别性能差等不足，本团队利用图神经网络技术实现产业升级，致力于完成以下目标：(1) 基于图神经网络技术挖掘药物的空间结构信息，提高药物研发效率，降低药物研发成本并为已批准的药物寻找新的适应症和靶点；(2) 采用异构邻域图网络实现对组学数据的区分和信息捕获，提升对多组学数据中关键信息的提取和在药物发现中的泛化能力，探索以现有药物新的可治疗疾病。

本团队基于图神经网络所提出的药物发现方案属于新工科人工智能技术，具有低成本和高通量的特性，能够高效对药物靶标和作用疾病进行预测，降低了药物研发周期，为发现药物的新适应症指明了方向。我们的方案为人工智能与制药行业交叉应用提供了重要实例，助力药物研发。

六、总结

为解决药物重定位研究中药物-靶点相互作用预测和药物-疾病相互作用预测这两种典型任务,本团队基于图神经网络,并根据各自任务的特点,对卷积神经网络进行不同方面的改进,主要工作如下:

(1)针对药物-靶点相互作用预测任务中缺乏对药物分子空间结构信息的利用的不足,本研究提出了融合多层图信息的 Transformer 网络,用于 DTI 的预测。Deep MGT 通过将药物分子的 SMILES 序列表示为图结构,使用分子补全图卷积神经网络对药物分子结构特性进行提取,最后使用 Transformer 网络来提取图神经网络不同隐藏层中的信息,来捕获药物化合物分子结构中原子的特征信息,更深层次的挖掘药物分子结构中不同原子之间的相互作用信息,克服 GCN 对边特征学习的不足。同时使用卷积神经网络来捕获靶点序列中局部残基信息,提取靶点的特征信息。相比于其他基于靶点序列结构的模型,我们的模型具有更好的性能;在药物重定位实验中,该模型可以找到 COVID-19 的治疗药物,证明了该模型具有药物发现的能力。

(2)根据药物-疾病相互作用预测任务中组学数据来源广泛的特性和异构网络缺乏邻域信息交互的不足,本研究提出了基于邻域对比学习异构图神经网络,用于 DDI 的预测。HNNCL 基于药物相似性网络、疾病相似性网络,并基于药物和疾病特征相似度构建了药物-疾病关联关系的异构网络。在 GCN 的基础上针对药物-药物(疾病-疾病)相似性网络和药物-疾病关联网络的特性,分别使用 SNFEM 和 MNFEM 提取药物和疾病的特征信息;然后利用对比学习融合单一领域特征和多邻域特征,降低模型对先验知识的依赖性;最后使用全连接网络进行药物-疾病关联关系的预测,并将三元损失与药物-疾病关系预测损失相结合,提升模型的泛化能,进一步降低模型对先验知识的依赖性。相关实验结果证明,HNNCL 在预测药物-疾病相互作用关系方面具有更好的性能,并具有发现阿尔茨海默症治疗药物的能力。

七、参考文献

- [1] R M Plenge, E M Scolnick, D Altshuler. Validating Therapeutic Targets through Human Genetics[J]. Nature Reviews Drug Discovery, 2013, 12(8): 581-594.
- [2] S Kato, S L Moulder, N T Ueno, et al. Challenges and Perspective of Drug Repurposing Strategies in Early Phase Clinical Trials[J]. Oncoscience, 2015, 2(6): 576-580.
- [3] J W Scannell, A Blanckley, H Boldon, et al. Diagnosing the Decline in Pharmaceutical R&D Efficiency[J]. Nature Reviews Drug Discovery, 2012, 11(3): 191-200.
- [4] M Baedeker, M S Ringel, U Schulze, 2021 FDA Approvals: Value Driven by COVID-19 Vaccines[R]. Nature Reviews Drug discovery, 2022.
- [5] D G Brown, H J Wobst. A Decade of FDA-Approved Drugs (2010–2019): Trends and Future Directions[J]. Journal of Medicinal Chemistry, 2021, 64(5): 2312-2338.
- [6] H Munos Bernard, W Chin William. How to Revive Breakthrough Innovation in the Pharmaceutical Industry[J]. Science Translational Medicine, 2011, 3(89): 16-26.
- [7] 景筱竹. 基于多源数据融合的药物重定位方法研究[D]. 哈尔滨: 哈尔滨工业大学, 2021.
- [8] N Novac. Challenges and Opportunities of Drug Repositioning[J]. Trends in Pharmacological Sciences, 2013, 34(5): 267-272.
- [9] X Pan, X Lin, D Cao, et al. Deep Learning for Drug Repurposing: Methods, Databases, and Applications[J]. WIREs Computational Molecular Science, 2022: e1597.
- [10] H Ye, Q Liu, J Wei. Construction of Drug Network Based on Side Effects and Its Application for Drug Repositioning[J]. PloS One, 2014, 9(2): e87864.
- [11] C Harrison. Coronavirus Puts Drug Repurposing on the Fast Track[J]. Nature Biotechnology, 2020, 38(4): 379-381.
- [12] J Setoain, M Franch, M Martínez, et al. NFFINDER: An Online Bioinformatics Tool for Searching Similar Transcriptomics Experiments in the Context of Drug Repositioning[J]. Nucleic Acids Research, 2015, 43(W1): W193-W199.
- [13] D S Wishart, Y D Feunang, A C Guo, et al. DrugBank 5.0: A Major Update to the DrugBank Database for 2018[J]. Nucleic Acids Research, 2018, 46(D1): D1074-D1082.
- [14] A F Shaughnessy. Old Drugs, New Tricks[J]. BMJ, 2011, 342: d741-d750.
- [15] R Gowthaman, S A Miller, S Rogers, et al. DARC: Mapping Surface Topography by Ray-Casting for Effective Virtual Screening at Protein Interaction Sites[J]. Journal of Medicinal Chemistry, 2016, 59(9): 4152-4170.
- [16] A Ezzat, P Zhao, M Wu, et al. Drug-Target Interaction Prediction with Graph Regularized Matrix Factorization[J]. IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2017, 14(3): 646-656.
- [17] A Gottlieb, G Y Stein, E Ruppin, et al. PREDICT: A Method for Inferring Novel Drug Indications with Application to Personalized Medicine[J]. Molecular Systems Biology, 2011, 7: 496-505.
- [18] C Sun, Y Cao, J-M Wei, et al. Autoencoder-Based Drug-Target Interaction Prediction by Preserving the Consistency of Chemical Properties and Functions of Drugs[J]. Bioinformatics, 2021, 37(20): 3618-3625.
- [19] P Xuan, L Gao, N Sheng, et al. Graph Convolutional Autoencoder and Fully-Connected Autoencoder with Attention Mechanism Based Method for Predicting Drug-Disease Associations[J]. IEEE Journal of Biomedical and Health Informatics, 2021, 25(5): 1793-1804.
- [20] I Lee, J Keum, H Nam. DeepConv-DTI: Prediction of Drug-Target Interactions Via Deep

- Learning with Convolution on Protein Sequences[J]. PLOS Computational Biology, 2019, 15(6): e1007129.
- [21] Z Yu, F Huang, X Zhao, et al. Predicting Drug-Disease Associations through Layer Attention Graph Convolutional Network[J]. Briefings in Bioinformatics, 2021, 22(4): bbaa243.
- [22] K Huang, C Xiao, L M Glass, et al. MolTrans: Molecular Interaction Transformer for Drug-Target Interaction Prediction[J]. Bioinformatics, 2021, 37(6): 830-836.
- [23] L Gao, H Cui, T Zhang, et al. Prediction of Drug-Disease Associations by Integrating Common Topologies of Heterogeneous Networks and Specific Topologies of Subnets[J]. Briefings in Bioinformatics, 2022, 23(1): bbab467.
- [24] Q Zhao, H Zhao, K Zheng, et al. HyperAttentionDTI: Improving Drug-Protein Interaction Prediction by Sequence-Based Deep Learning with Attention Mechanism[J]. Bioinformatics, 2022, 38(3): 655-662.
- [25] Y Chu, A C Kaushik, X Wang, et al. DTI-CDF: A Cascade Deep Forest Model Towards the Prediction of Drug-Target Interactions Based on Hybrid Features[J]. Briefings in Bioinformatics, 2021, 22(1): 451-462.
- [26] X Zhang, L Li, M K Ng, et al. Drug-Target Interaction Prediction by Integrating Multiview Network Data[J]. Computational Biology and Chemistry, 2017, 69: 185-193.
- [27] K Huang, T Fu, L M Glass, et al. DeepPurpose: A Deep Learning Library for Drug-Target Interaction Prediction[J]. Bioinformatics, 2020, 36(22-23): 5545-5547.
- [28] T Nguyen, H Le, T P Quinn, et al. GraphDTA: Predicting Drug-Target Binding Affinity with Graph Neural Networks[J]. Bioinformatics, 2021, 37(8): 1140-1147.
- [29] Q Liu, Z Hu, R Jiang, et al. DeepCDR: A Hybrid Graph Convolutional Network for Predicting Cancer Drug Response[J]. Bioinformatics, 2020, 36(2): 911-918.
- [30] F Wan, L Hong, A Xiao, et al. NeoDTI: Neural Integration of Neighbor Information from a Heterogeneous Network for Discovering New Drug-Target Interactions[J]. Bioinformatics, 2019, 35(1): 104-111.
- [31] B-W Zhao, L Hu, Z-H You, et al. HINGRL: Predicting Drug-Disease Associations with Graph Representation Learning on Heterogeneous Information Networks[J]. Briefings in Bioinformatics, 2021, 23(1): bbab515.
- [32] L Cai, C Lu, J Xu, et al. Drug Repositioning Based on the Heterogeneous Information Fusion Graph Convolutional Network[J]. Briefings in Bioinformatics, 2021, 22(6): bbab319.
- [33] S Wang, Z Du, M Ding, et al. KG-DTI: A Knowledge Graph Based Deep Learning Method for Drug-Target Interaction Predictions and Alzheimer's Disease Drug Repositions[J]. Applied Intelligence, 2022, 52(1): 846-857.
- [34] H Luo, M Li, S Wang, et al. Computational Drug Repositioning Using Low-Rank Matrix Approximation and Randomized Algorithms[J]. Bioinformatics, 2018, 34(11): 1904-1912.
- [35] J R Bock, D A Gough. Virtual Screen for Ligands of Orphan G Protein-Coupled Receptors[J]. Journal of Chemical Information and Modeling, 2005, 45(5): 1402-1414.
- [36] M Takarabe, M Kotera, Y Nishimura, et al. Drug Target Prediction Using Adverse Event Report Systems: A Pharmacogenomic Approach[J]. Bioinformatics, 2012, 28(18): 611-618.
- [37] F Napolitano, Y Zhao, V M Moreira, et al. Drug Repositioning: A Machine-Learning Approach through Data Integration[J]. Journal of Cheminformatics, 2013, 5(1): 1-9.
- [38] Y LeCun, Y Bengio, G Hinton. Deep Learning[J]. Nature, 2015, 521(7553): 436-444.
- [39] E Gawehn, J A Hiss, G Schneider. Deep Learning in Drug Discovery[J]. Molecular Informatics,

2016, 35(1): 3-14.

[40] S Ekins. The Next Era: Deep Learning in Pharmaceutical Research[J]. *Pharmaceutical Research*, 2016, 33(11): 2594-2603.

[41] 高金贺. 基于生物医学语义数据的药物-疾病相互作用关系预测研究[D]. 天津: 天津大学, 2019.

[42] 彭利红. 药物—靶标相互作用预测及其在药物重定位中的应用研究[D]. 长沙: 湖南大学, 2017.

[43] 尹晓尧. 面向复杂疾病诊疗的组学大数据分析方法及应用[D]. 长沙: 国防科技大学, 2019.

[44] Y-B Wang, Z-H You, S Yang, et al. A Deep Learning-Based Method for Drug-Target Interaction Prediction Based on Long Short-Term Memory Neural Network[J]. *BMC Medical Informatics and Decision Making*, 2020, 20(2): 1-9.

[45] Y-C Wang, C-H Zhang, N-Y Deng, et al. Kernel-Based Data Fusion Improves the Drug-Protein Interaction Prediction[J]. *Computational Biology and Chemistry*, 2011, 35(6): 353-362.

[46] Z Yang, W Zhong, L Zhao, et al. ML-DTI: Mutual Learning Mechanism for Interpretable Drug-Target Interaction Prediction[J]. *The Journal of Physical Chemistry Letters*, 2021, 12(17): 4247-4261.

[47] J Li, Z Lu. A New Method for Computational Drug Repositioning Using Drug Pairwise Similarity[C]. *Proceedings of the 2012 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, Philadelphia, United States, 2012: 1-4.

[48] M Zhou, Y Chen, R Xu. A Drug-Side Effect Context-Sensitive Network Approach for Drug Target Prediction[J]. *Bioinformatics*, 2019, 35(12): 2100-2107.

[49] J Li, J Wang, H Lv, et al. IMCHGAN: Inductive Matrix Completion with Heterogeneous Graph Attention Networks for Drug-Target Interactions Prediction[J]. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 2021: 1-10.

[50] J Tang, M Qu, M Wang, et al. Line: Large-Scale Information Network Embedding[C]. *Proceedings of the 24th International Conference on World Wide Web (WWW)*, Florence, Italy, 2015: 1067-1077.

[51] D Sosa, A Derry, M Guo, et al. A Literature-Based Knowledge Graph Embedding Method for Identifying Drug Repurposing Opportunities in Rare Diseases[J]. *Pacific Symposium on Biocomputing Pacific Symposium on Biocomputing*, 2020, 25: 463-474.

[52] D Morselli Gysi, Í do Valle, M Zitnik, et al. Network Medicine Framework for Identifying Drug-Repurposing Opportunities for COVID-19[J]. *Proceedings of the National Academy of Sciences*, 2021, 118(19): e2025581118.

[53] R Zhang, D Hristovski, D Schutte, et al. Drug Repurposing for COVID-19 Via Knowledge Graph Completion[J]. *Journal of Biomedical Informatics*, 2021, 115: 103696.

[54] Y Chen, T Ma, X Yang, et al. Muffin: Multi-Scale Feature Fusion for Drug-Drug Interaction Prediction[J]. *Bioinformatics*, 2021, 37(17): 2651-2658.

[55] M A Yıldırım, K-I Goh, M E Cusick, et al. Drug-Target Network[J]. *Nature Biotechnology*, 2007, 25(10): 1119-1126.

[56] E E Schadt. Molecular Networks as Sensors and Drivers of Common Human Diseases[J]. *Nature*, 2009, 461(7261): 218-223.

[57] F Iorio, J Saez-Rodriguez, D Bernardo. Network Based Elucidation of Drug Response: From Modulators to Targets[J]. *BMC Systems Biology*, 2013, 7(1): 1-9.

- [58] 余冬华. 基于聚类分析的药物-靶标互作关系预测方法研究[D]. 哈尔滨: 哈尔滨工业大学, 2020.
- [59] 陈鹏, 鲍天嘉智, 余肖生. 基于多相似度融合的药物重定位推荐算法[J]. 计算机技术与发展, 2021, 31(01): 168-174.
- [60] 鱼亮, 赵晋. 基于组织特异性和直接邻居相似度方法预测疾病-药物关系[J]. 中国科学: 信息科学, 2019, 49(09): 1175-1185.
- [61] 李苗苗. 基于 XG-BOOST 和多数据源的药物重定位预测[J]. 软件导刊, 2020, 19(02): 110-113.
- [62] J Li, Z Lu. Pathway-Based Drug Repositioning Using Causal Inference[J]. BMC Bioinformatics, 2013, 14(16): 1-10.
- [63] C Wu, R C Gudivada, B J Aronow, et al. Computational Drug Repositioning through Heterogeneous Network Clustering[J]. BMC Systems Biology, 2013, 7(5): 1-9.
- [64] C Cui, X Ding, D Wang, et al. Drug Repurposing against Breast Cancer by Integrating Drug-Exposure Expression Profiles and Drug-Drug Links Based on Graph Neural Network[J]. Bioinformatics, 2021, 37(18): 2930-2937.
- [65] A Krizhevsky, I Sutskever, G E Hinton. ImageNet Classification with Deep Convolutional Neural Networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [66] Y Lecun, L Bottou, Y Bengio, et al. Gradient-Based Learning Applied to Document Recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [67] C Szegedy, L Wei, J Yangqing, et al. Going Deeper with Convolutions[C]. Proceedings of the 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Boston, United States, 2015: 1-9.
- [68] K He, X Zhang, S Ren, et al. Deep Residual Learning for Image Recognition[C]. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Los Angeles, United States, 2016: 770-778.
- [69] C Jin, M Schenkel, S Carlile. Neural System Identification Model of Human Sound Localization[J]. The Journal of the Acoustical Society of America, 2000, 108: 1215-1235.
- [70] S Hochreiter, J Schmidhuber. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [71] K Cho, B van Merriënboer, C Gulcehre, et al. Learning Phrase Representations Using RNN Encoder-Decoder for Statistical Machine Translation[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), Doha, Qatar, 2014: 1724-1734.
- [72] Thomas, M Welling. Semi-Supervised Classification with Graph Convolutional Networks[C]. Proceedings of the 2017 International Conference of Legal Regulators (ICLR), Toulon, France, 2017: abs/1609.02907.
- [73] F Scarselli, M Gori, A C Tsoi, et al. The Graph Neural Network Model[J]. IEEE Transactions on Neural Networks, 2009, 20(1): 61-80.
- [74] A Grover, J Leskovec. Node2vec: Scalable Feature Learning for Networks[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD). San Francisco, United States, 2016: 855-864.
- [75] A Vaswani, N Shazeer, N Parmar, et al. Attention Is All You Need[C]. Proceedings of the 31st International Conference on Neural Information Processing Systems (NeurIPS), California, United States, 2017: 6000-6010.
- [76] U Maziarka, T Danel, S Mucha, et al. Molecule Attention Transformer[J]. arXiv pre-print

server, 2020.

[77] J Robinson, C-Y Chuang, S Sra, et al. Contrastive Learning with Hard Negative Samples[C]. Proceedings of the 2021 International Conference of Legal Regulators (ICLR), Online, 2021: abs/2010.04592.

[78] Y Wang, Y Min, X Chen, et al. Multi-View Graph Contrastive Representation Learning for Drug-Drug Interaction Prediction[C]. Proceedings of the Web Conference 2021 (WWW), Ljubljana, Slovenia, 2021: 2921–2933.

[79] F Schroff, D Kalenichenko, J Philbin. FaceNet: A Unified Embedding for Face Recognition and Clustering[C]. Proceedings of the 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Boston, United States, 2015: 815-823.

[80] C Tang, C Zhong, D Chen, et al. Drug-Target Interactions Prediction Using Marginalized Denoising Model on Heterogeneous Networks[J]. BMC Bioinformatics, 2020, 21(1): 1-29.

[81] M Kanehisa, S Goto, M Hattori, et al. From Genomics to Chemical Genomics: New Developments in Kegg[J]. Nucleic Acids Research, 2006, 34(D1): D354-D357.

[82] Y Wang, S H Bryant, T Cheng, et al. PubChem Bioassay: 2017 Update[J]. Nucleic Acids Research, 2017, 45(D1): D955-D963.

[83] L Breiman. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.

[84] C Cortes, V Vapnik. Support-Vector Networks[J]. Machine Learning, 1995, 20(3): 273-297.

[85] H Öztürk, A Özgür, E Ozkirimli. DeepDTA: Deep Drug-Target Binding Affinity Prediction[J]. Bioinformatics, 2018, 34(17): 821-829.

[86] M Wen, Z Zhang, S Niu, et al. Deep-Learning-Based Drug-Target Interaction Prediction[J]. Journal of Proteome Research, 2017, 16(4): 1401-1409.

[87] L Chen, X Tan, D Wang, et al. TransformerCPI: Improving Compound-Protein Interaction Prediction by Sequence-Based Deep Learning with Self-Attention Mechanism and Label Reversal Experiments[J]. Bioinformatics, 2020, 36(16): 4406-4414.

[88] J Lopez Bernal, N Andrews, C Gower, et al. Effectiveness of COVID-19 Vaccines against the B.1.617.2 (Delta) Variant[J]. New England Journal of Medicine, 2021, 385(7): 585-594.

[89] N E El-Ashmawy, A-H A Lashin, K M Okasha, et al. The Plausible Mechanisms of Tramadol for Treatment of COVID-19[J]. Medical Hypotheses, 2021, 146: 110468.

[90] A Carpinteiro, M J Edwards, M Hoffmann, et al. Pharmacological Inhibition of Acid Sphingomyelinase Prevents Uptake of Sars-Cov-2 by Epithelial Cells[J]. Cell Reports Medicine, 2020, 1(8): 100142.

[91] C T D Raj, D K Kandaswamy, R C S R Danduga, et al. COVID-19: Molecular Pathophysiology, Genetic Evolution and Prospective Therapeutics-A Review[J]. Archives of Microbiology, 2021, 203(5): 2043-2057.

[92] I Sarkar, A Sen. In Silico Screening Predicts Common Cold Drug Dextromethorphan Along with Prednisolone and Dexamethasone Can Be Effective against Novel Coronavirus Disease (COVID-19)[J]. Journal of Biomolecular Structure and Dynamics, 2020: 1-5.

[93] M Kanehisa, S Goto, M Hattori, et al. From Genomics to Chemical Genomics: New Developments in Kegg[J]. Nucleic Acids Research, 2006, 34(D1): D354-D357.

[94] J Kim, J M Basak, D M Holtzman. The Role of Apolipoprotein E in Alzheimer's Disease[J]. Neuron, 2009, 63(3): 287-303.

[95] P Thomas, M Fenech. A Review of Genome Mutation and Alzheimer's Disease[J]. Mutagenesis, 2007, 22(1): 15-33.

- [96] H Luo, J Wang, M Li, et al. Drug Repositioning Based on Comprehensive Similarity Measures and Bi-Random Walk Algorithm[J]. *Bioinformatics*, 2016, 32(17): 2664-2671.
- [97] X Liang, P Zhang, L Yan, et al. LRSSL: Predict and Interpret Drug-Disease Associations Based on Data Integration Using Sparse Subspace Learning[J]. *Bioinformatics*, 2017, 33(8): 1187-1196.
- [98] A Hamosh, A F Scott, J Amberger, et al. Online Mendelian Inheritance in Man (OMIM), a Knowledgebase of Human Genes and Genetic Disorders[J]. *Nucleic Acids Research*, 2002, 30(1): 52-55.
- [99] F Wang, P Zhang, N Cao, et al. Exploring the Associations between Drug Side-Effects and Therapeutic Indications[J]. *Journal of Biomedical Informatics*, 2014, 51: 15-23.
- [100] A P Davis, C J Grondin, R J Johnson, et al. Comparative Toxicogenomics Database (CTD): Update 2021[J]. *Nucleic Acids Research*, 2021, 49(D1): D1138-D1143.
- [101] C Steinbeck, Y Han, S Kuhn, et al. The Chemistry Development Kit (CDK): An Open-Source Java Library for Chemo-and Bioinformatics[J]. *Journal of Chemical Information and Computer Sciences*, 2003, 43(2): 493-500.
- [102] M A van Driel, J Bruggeman, G Vriend, et al. A Text-Mining Analysis of the Human Phenome[J]. *European Journal of Human Genetics*, 2006, 14(5): 535-542.
- [103] H Zhu, F Feng, X He, et al. Bilinear Graph Neural Network with Neighbor Interactions[C]. *Proceedings of the 29 International Joint Conference on Artificial Intelligence (IJCAI)*, Yokohama, Japan, 2020: 1452-1458.
- [104] Y Liu, M Wu, C Miao, et al. Neighborhood Regularized Logistic Matrix Factorization for Drug-Target Interaction Prediction[J]. *PLOS Computational Biology*, 2016, 12(2): e1004760.
- [105] W Zhang, X Yue, W Lin, et al. Predicting Drug-Disease Associations by Using Similarity Constrained Matrix Factorization[J]. *BMC Bioinformatics*, 2018, 19(1): 1-12.
- [106] W Zhang, H Xu, X Li, et al. DRIMC: An Improved Drug Repositioning Approach Using Bayesian Inductive Matrix Completion[J]. *Bioinformatics*, 2020, 36(9): 2839-2847.
- [107] J Li, S Zhang, T Liu, et al. Neural Inductive Matrix Completion with Graph Convolutional Networks for Mirna-Disease Association Prediction[J]. *Bioinformatics*, 2020, 36(8): 2538-2546.
- [108] S Erkulwater, R Pillai. Amantadine and the End-Stage Dementia of Alzheimer's Type[J]. *Southern Medical Journal*, 1989, 82(5): 550-554.
- [109] D Peng, R Yuan X Fau - Zhu, R Zhu. Memantine Hydrochloride in the Treatment of Dementia Subtypes[J]. *Journal of Clinical Neuroscience*, 2013, 20(11): 1482-1485.
- [110] G Lefèvre, F Callegari, S Gsteiger, et al. Effects of Renal Impairment on Steady-State Plasma Concentrations of Rivastigmine: A Population Pharmacokinetic Analysis of Capsule and Patch Formulations in Patients with Alzheimer's Disease[J]. *Drugs & Aging*, 2016, 33(10): 725-736.
- [111] O Ambrée, H Richter, N Sachser, et al. Levodopa Ameliorates Learning and Memory Deficits in a Murine Model of Alzheimer's Disease[J]. *Neurobiology of Aging*, 2009, 30(8): 1192-1204.